Robenson MONDELICE

Segmentation sémantique de données CT-scans par apprentissage semi-supervisé

SOMMAIRE

1. Contexte
2. Présentation des données
3. Matériel et méthodes
4. Résultats
5. Discussion et conclusion

1. Contexte

CT- Scan (Computed Tomography Scanner):

Type d'images médicales détaillées et tridimensionnelles (coronal, sagittal, axial) obtenus par rayons X qui permettent de visualiser l'anatomie du corps humain

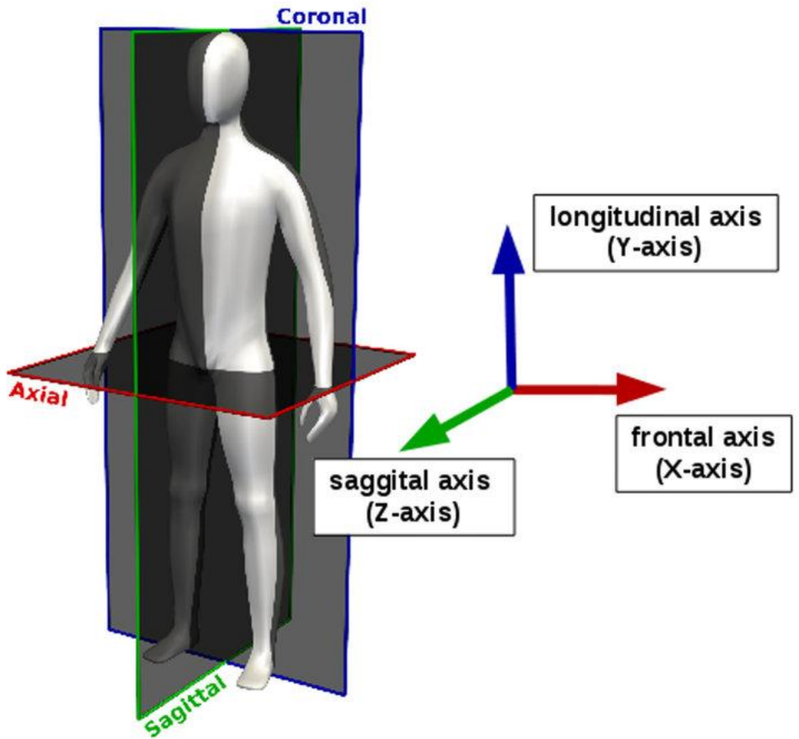

Segmentation sémantique :

Tâche de **vision par ordinateur** qui consiste à **attribuer une étiquette de classe à chaque pixel d'une image afin de classifier chaque partie de l'image**

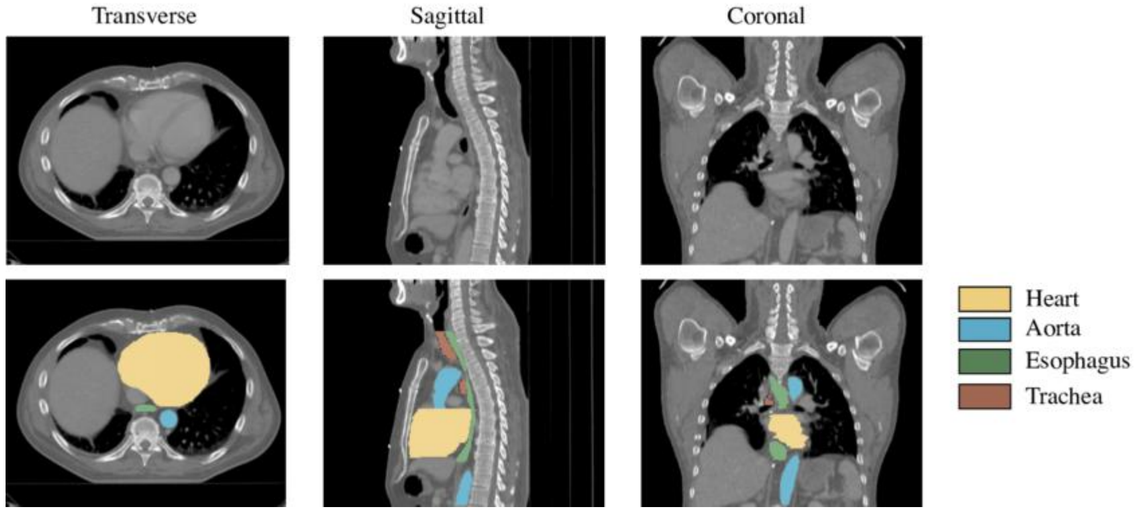

→ Tâche manuellement réalisé par les radiologues

→ **Limité à six scanners par heure**

→ Volonté **d'accélérer et faciliter le temps d'analyse** des radiologues

→ Détecter des anomalies(taille des organes, tumeurs) sur les images avec toujours un contrôle du médecin

UTILISER LE SCHEMA FAIT PRECEDEMMENT POUR ECHOPRIME

Raidium, start-up française, intéressé par cette solution

SEGMENTATION SEMANTIQUE

Images ↓ Intelligence artificielle

Automatiser un processus pour **segmenter ces structures anatomiques**

Dans le contexte de l'analyse des images médicales, par souci d'efficacité et d'ergonomie, on souhaiterait développer des modèles dont **la tâche principale est de détecter et de délimiter les structures anatomiques et pathologiques présentes** dans un CT-scan.

Possibilité d'application

Finalité du projet

2. Présentation des données

Présentation des données

Leurs caractéristiques

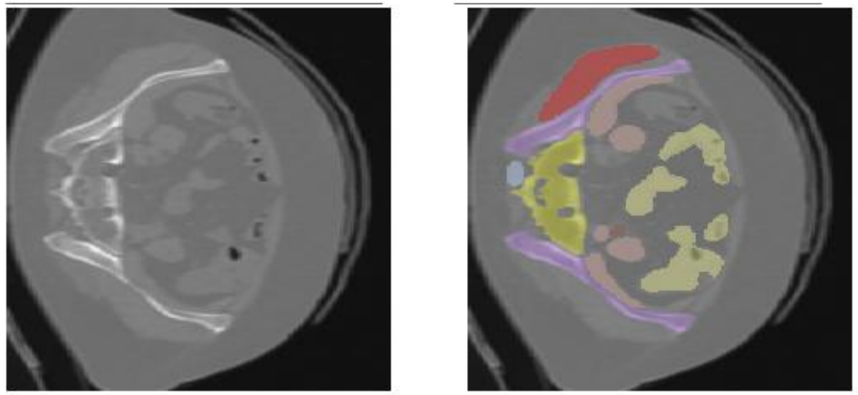

Changer cette image et mettre le 0 et le 1(si bien annoté) ou le suivant mieux annoté

0 est une valeur spéciale signifiant que ce pixel ne fait pas partie d'une structure et fait donc partie du fond

Et du coup modifier la page 12

Données d'entrainement:

- 2000 Images 256x256 pixels, noir et blanc
  - Différentes parties du corps
  - Coupe transverse
- Masque de segmentation associé(classe associée par pixel)
  - 54 classes différentes numérotées de 1 à 54 (organe, tumeur, anomalie..)
  - Une classe *background :* la classe 0

Présentation des données

… et quelques particularités

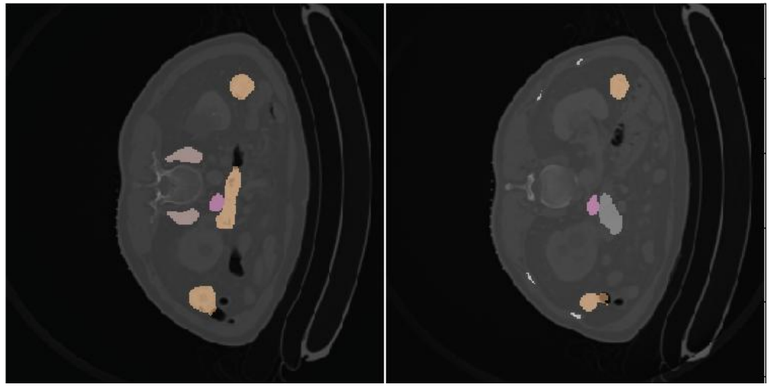

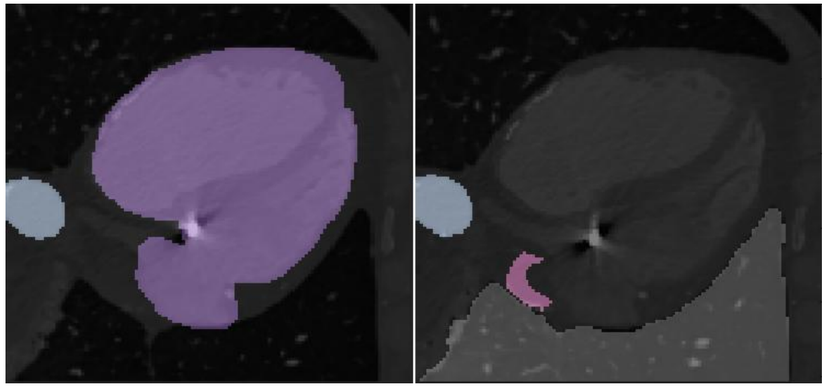

Données d'entrainement:

→ Des images **partiellement annotées et non annotés**

Des images similaires **mais segmentés différemment : chacune est donc annotée partiellement**

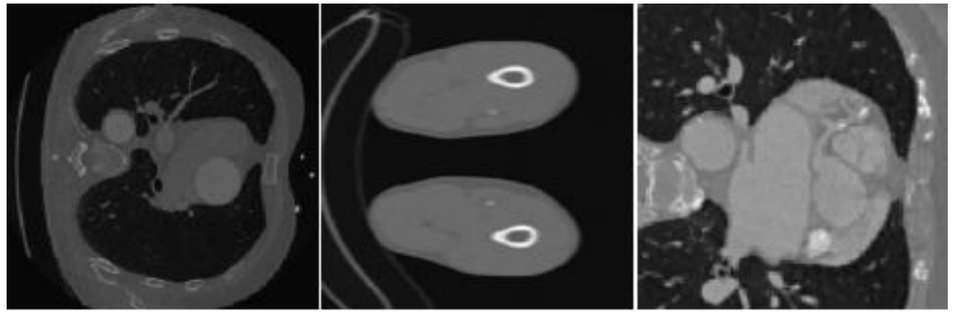

Des images avec **aucune structure annotée**

Présentation des données

… et quelques particularités

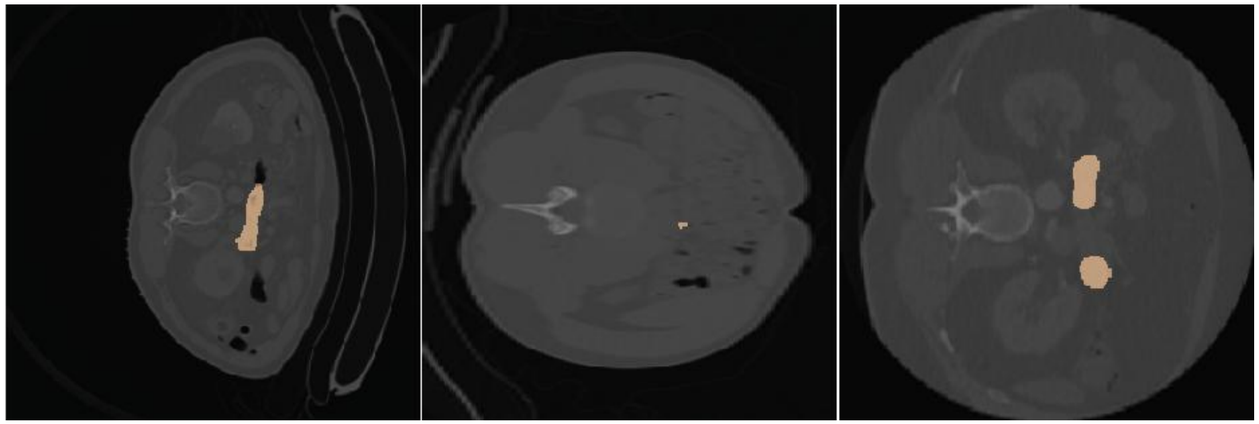

Le label 10 semble annoter des choses différentes selon les images

Données d'entrainement:

→ Des labels n'ont **pas la même signification** parmi les images partiellement annotées

Objectif du projet

Vue globale

Caractéristiques complexes ➔ Appel au Deep Learning et méthodes de segmentation

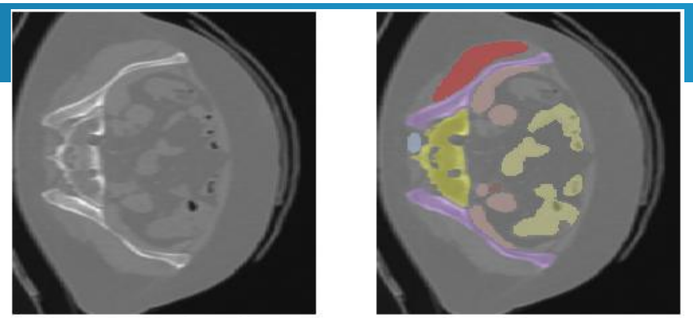

Données d'entrainement

Images

- Images **partiellement annotées de coupe transverse**
- **Masque de segmentation (classe par pixel)**

Modèle de segmentation pré-entrainé

- Identification et évaluation de **facteurs altérant la robustesse et la précision de l'estimation**

Phase d'ajustement (fine-tuning)

- Entrainement du modèle via Deep Learning sur nos données d'entrainement
- Choix **d'une méthode adaptée à notre challenge**

Evaluation

- Evaluation quantitative et quantitative
- Sélection d'hyperparamètres

Modèle de segmentation robuste et précis

Objectif du projet

Métrique d'un modèle de segmentation robuste : la Dice

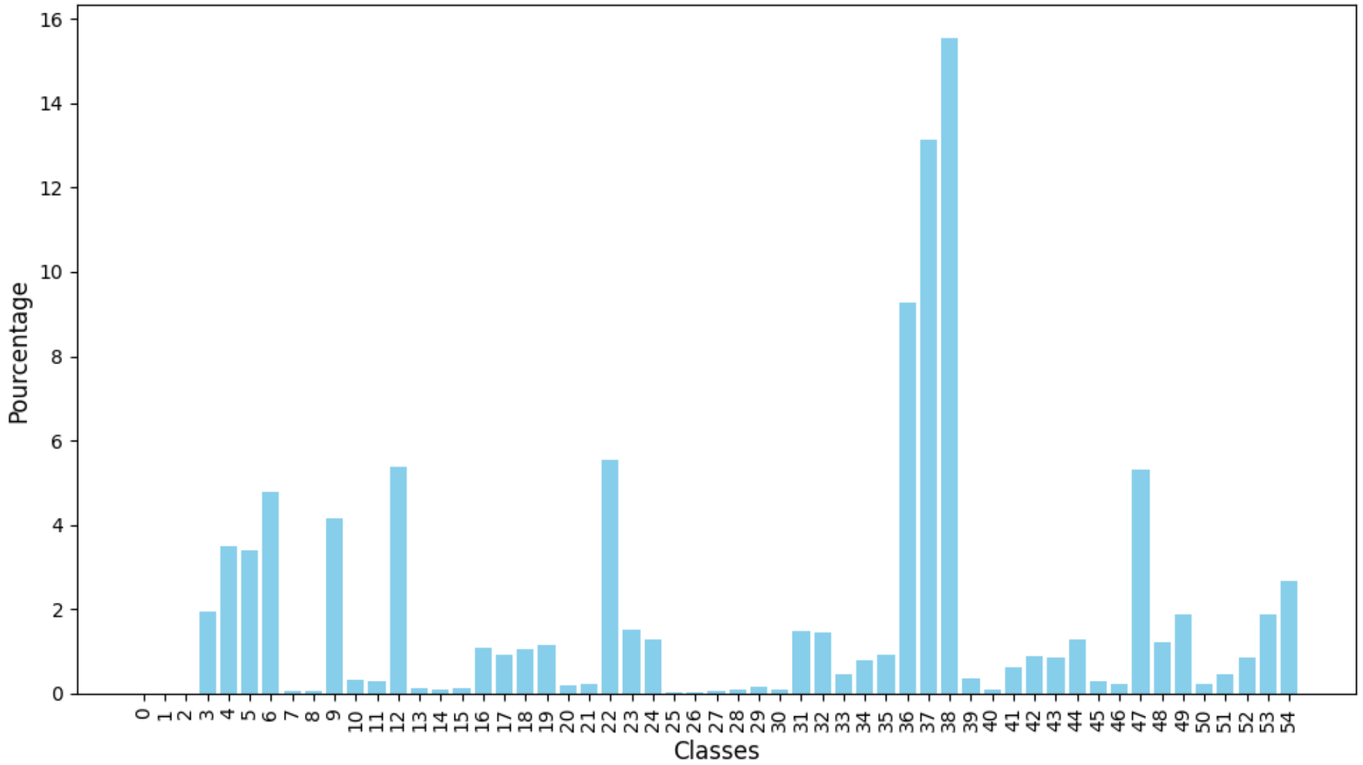

En excluant la classe 0,

Les classes 36,37,38 couvrent 37% des pixels labellisées à eux trois

---> forte classe imbalance

Histogramme de la répartition des classes (en pourcentage de pixels recouverts) sur l'ensemble d'entraînement

Objectif du projet

Métrique d'un modèle de segmentation robuste : la Dice

$$\text{Dice} = \frac{2\ X\ Area\ of\ overlap}{Total\ area} = \frac{2 \times \text{Prediction} \cap \text{Ground truth}}{\text{Prediction} + \text{Ground truth}}$$

Dice coefficient is calculated from the **precision** and **recall** of a prediction. Then, it scores from 0 to 1 the overlap between predicted segmentation and ground truth. It's a useful metric for highly class imbalanced datasets.

La Dice pour une classe donnée

Objectif du projet

Fonction de perte adaptée : la Dice Loss

La Dice Loss pour une classe donnée i est donc calculée comme suit :

$$\text{Dice Loss}_i = 1 - \frac{2\sum_{p \in S_i} y_p \hat{y}_p}{\sum_{p \in S_i} y_p + \sum_{p \in S_i} \hat{y}_p}$$

La **Dice Loss** totale est alors la moyenne des Dice Loss de toutes les classes :

$$\text{Dice Loss} = \frac{1}{C} \sum_{i=1}^{C} \text{Dice Loss}_i$$

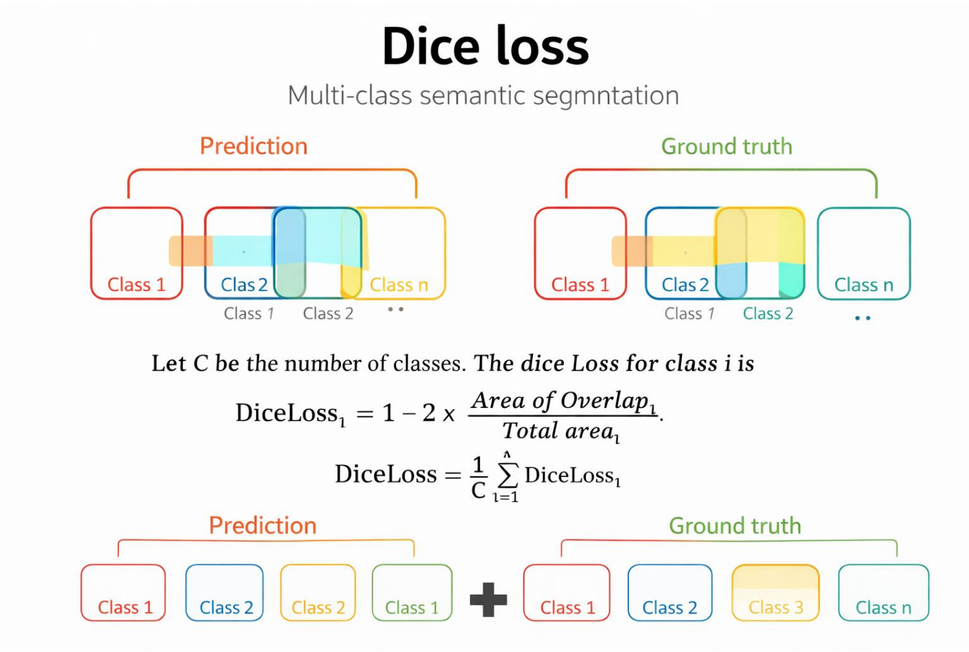

Trouver la police de l'image précédente pour corriger cela.

Ma définition de la DiceLoss est mauvaise car il faudrait qu'on considérer d'abord pour chaque classe une conversion en one-hot tensor

3. Matériel et méthodes

Entrainement supervisé : notre matériel d'entrainement

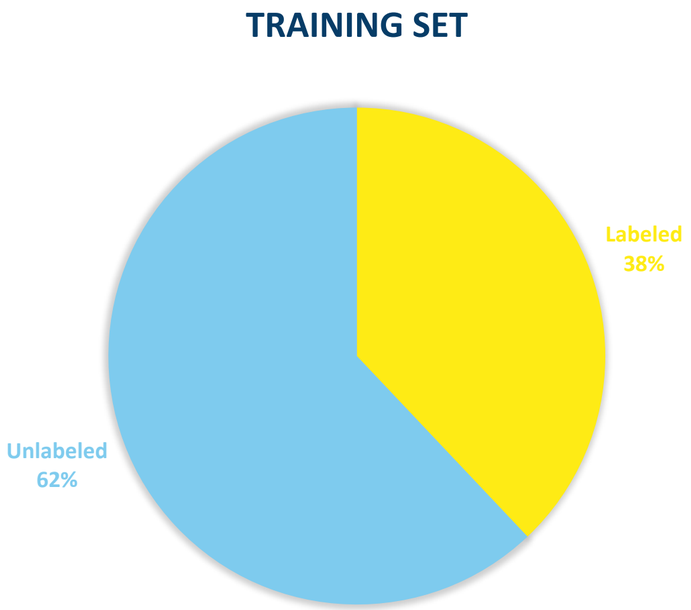

Choix d’un entrainement supervisé

- Création d'une classe LabeledDataset considérant seulement les images tels que il n'y ait au moins une structure labellisée
- Utilisation des 759 images partiellement annotées qui va composer notre jeu d’entraînement

Preprocessing phase

Choix des data augmentations

Aire moyenne couverte par label par image

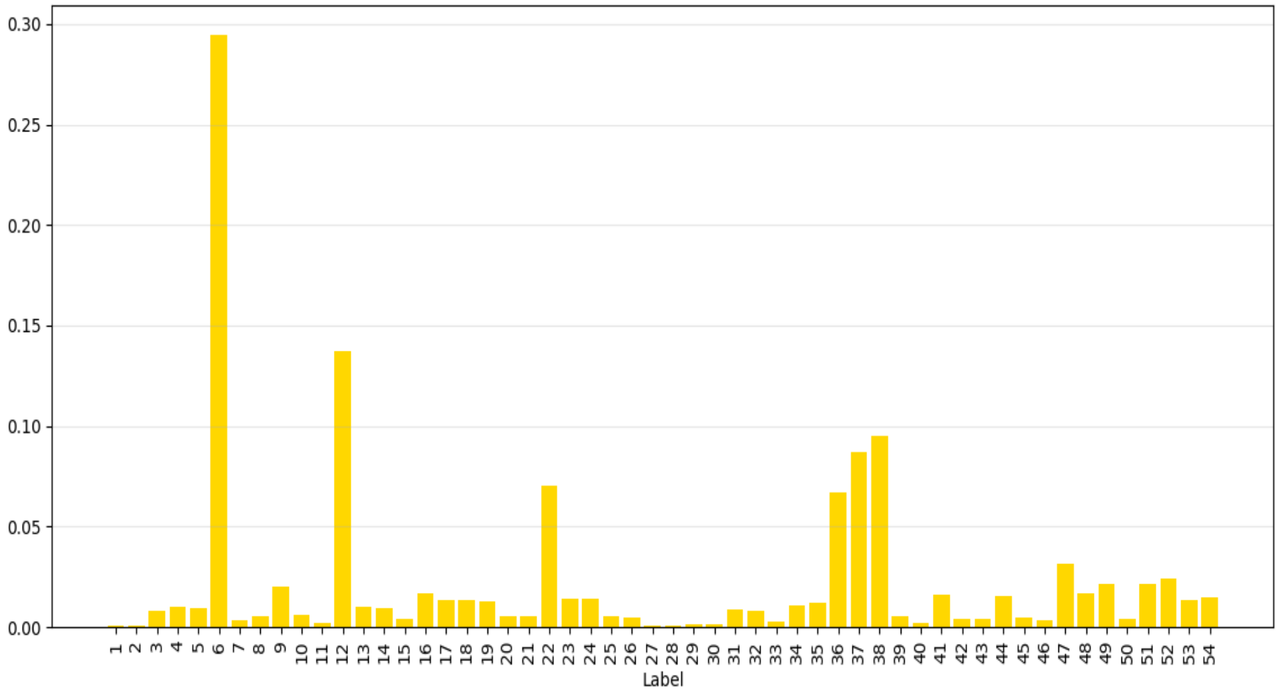

Distribution des classes : pourcentage de pixels couverts

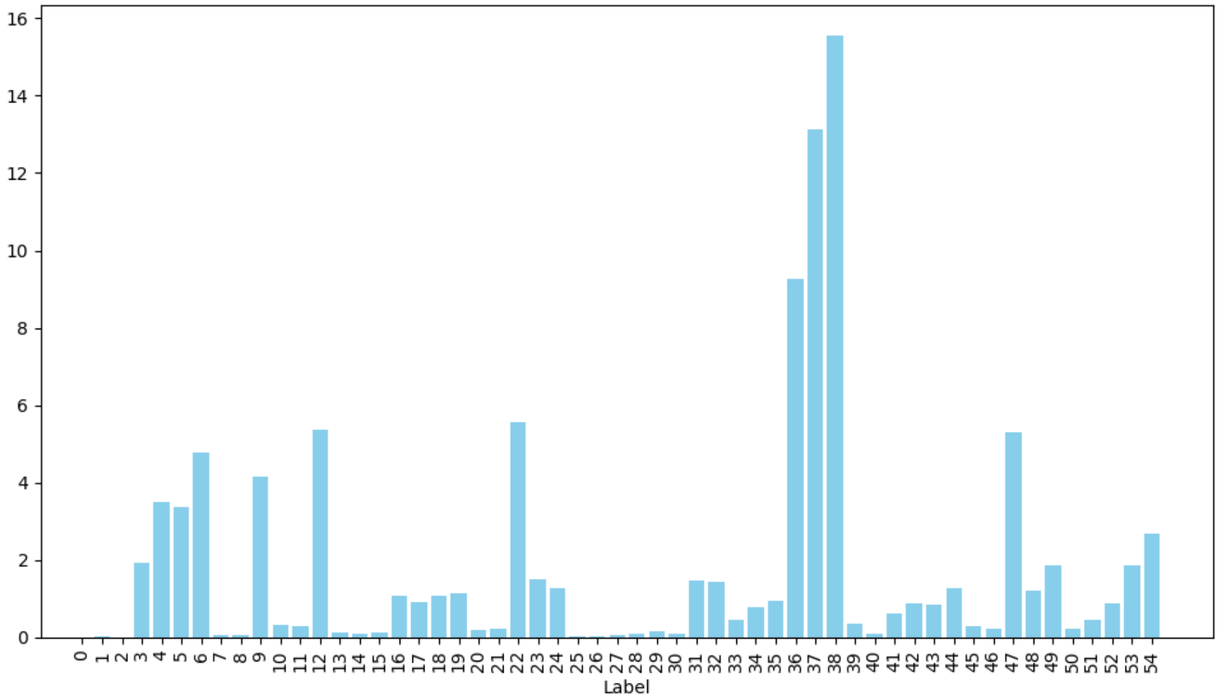

- Fort déséquilibre des classes
- Labels présentent une aire moyenne variant de <1% à 28%
- **INTERET A FAIRE DES DATA AUGMENTATIONS PERTINENTES**

Identification des contraintes

Un matériel d'entrainement inexploité

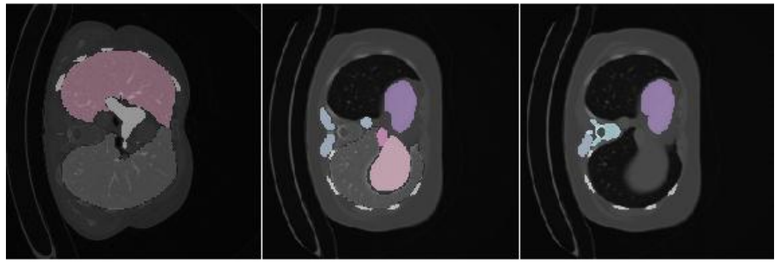

40.png - 42.png

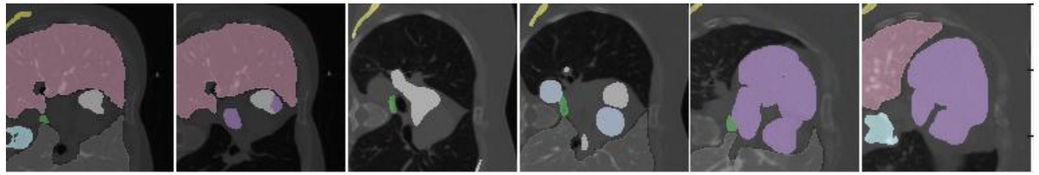

106.png - 111.png

CT Scan à axe commun mais différentes vues

→ Organes présentent des caractéristiques différentes
→ Intérêt de cropper

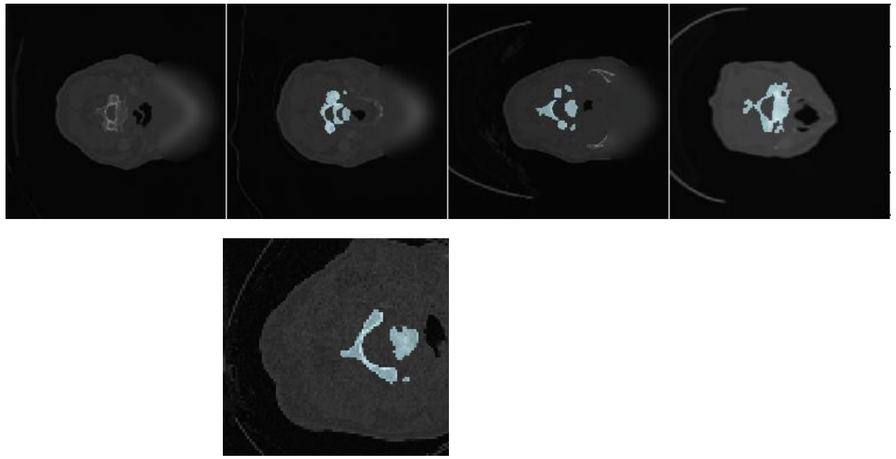

426.png

CT Scan de parties communes à différents niveaux d'axe

- Expose le modèle à **différentes régions** d'une même image
- Varie la **position relative des objets**
- Forcer l'apprentissage de contexte local
- Évite que le modèle apprenne des biais liés à la position

- TRANSITION : QUEL MODELE?

Choix des modèles de segmentation

SegFormer : un *state-of-the-art* Transformer

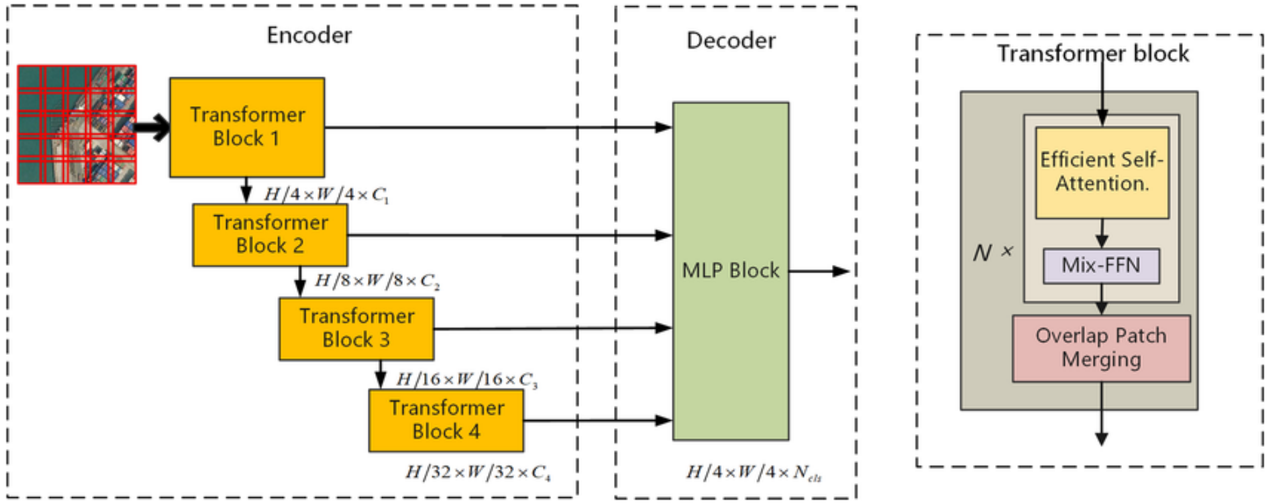

SegFormer, un modèle de segmentation **pré-entrainé** reposant sur deux structures principales :

- Encoder : extract both high-resolution fine features and low-resolution coarse features (**hierarchial feature map**)
- Decoder (All-MLP Decoder) : consiste en un lightweight decoder qui va aggréger ces features multi-échelles ,après upsampling à une taille commune, pour reconstruire le masque sémantique de sortie.

CHANGER L'IMAGE et MIEUX EXPLIQUER ET CHERCHER A COMPRENDRE SI C EST JUSTE DU LINEAR PROBING

SUPPOSER QUE C'EST PARCE QUE C'EST UN TRANSFORMER QU'IL SUCCEDE

Choix des data augmentations

Crop vs Sans crop

DICE Score sur l'ensemble de validation au bout de 20 epochs et 3 seeds :

setting	mean	std	min	max	variance
crop	0.452300	0.006764	0.448314	0.460110	0.000046
no_crop	0.434069	0.002930	0.430697	0.435999	0.000009

DICE Score de 0,4288 vs 0.4107 sur l'ensemble de test au bout de 20 epochs

Choix des modèles de segmentation

SegFormer : un *state-of-the-art* Transformer

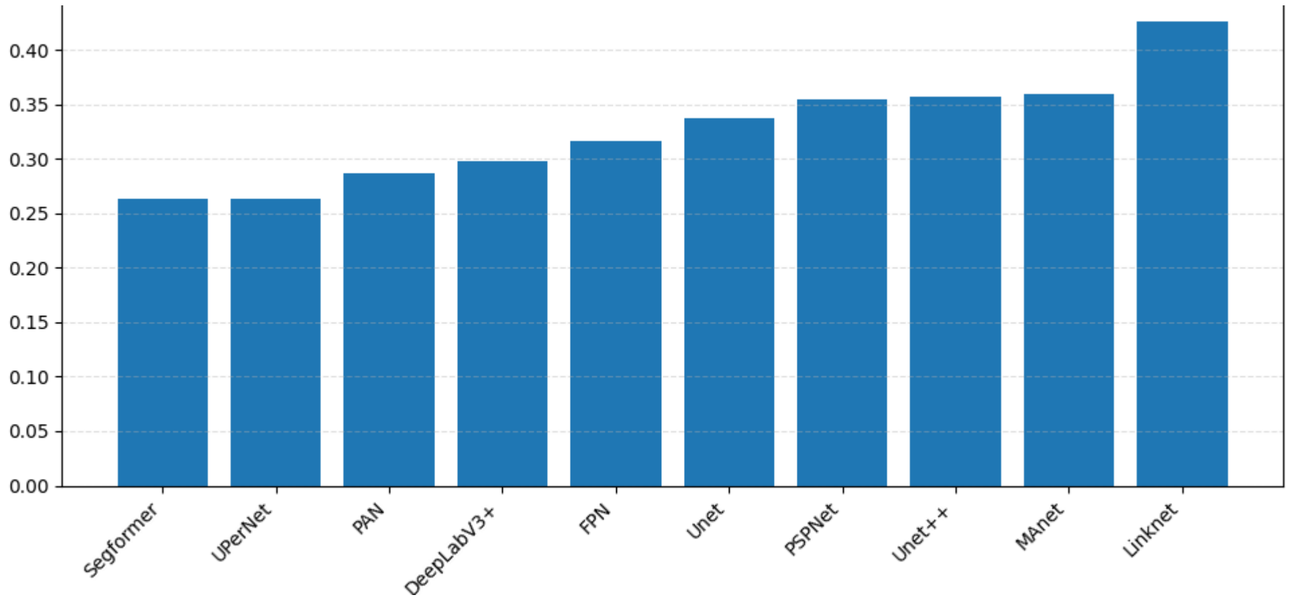

Comparaison de la Dice Loss (meilleure score) sur l'ensemble de validation au bout d'un entrainement (sur 10 epochs) de ces SOTA modèles de segmentation

Strategy and hyperparameters :

- **Hold-out validation** : 80% – 20%
- **Optimizer** : Adam
- **Learning rate** : 1e-3
- **Weights :** ImageNet
- **Augmentation** : Crop (20% à 80%) pour limiter l'omniprésence du label 0

Identification des contraintes --> CHANGER LE TITRE

Des marges d'amélioration perceptibles

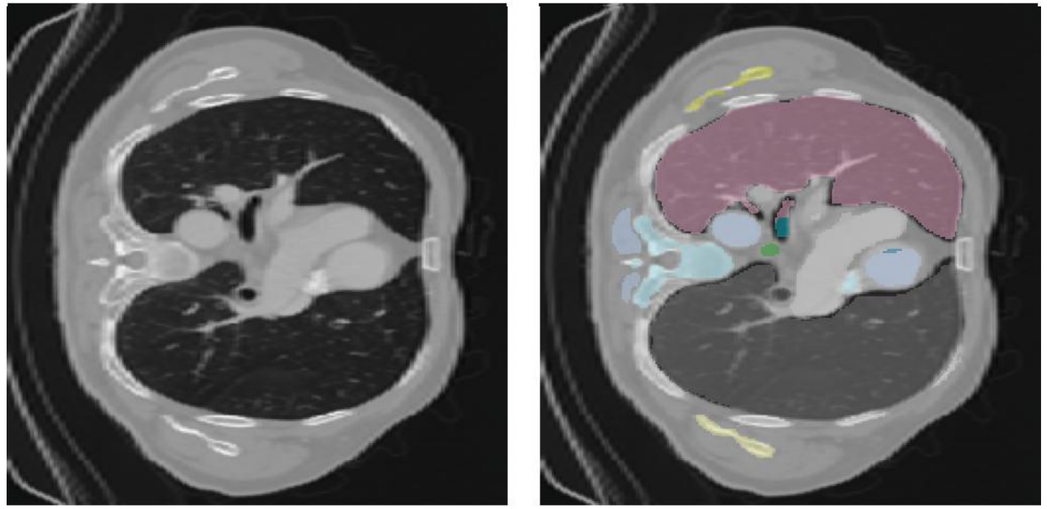

50.Png du test set

Un masque de segmentation incomplet

→ Recherche de structures uniformément segmentés

CHANGER D'IMAGE POUR AVOIR LA LEGENDE UNIFORME ET SUR UN NOUVEAU MODELE DE REFERENCE QUE JE VAIS ETABLIR PUIS LE FAIRE APRES COMPARAISON ET CA SERA INTERESSANT

NE DEVRAIT PAS ETRE LA A CE MOMENT CAR CE SONT DES IMAGES DU TEST SET

Identification des contraintes --> CHANGER LE TITRE

Des marges d'amélioration perceptibles

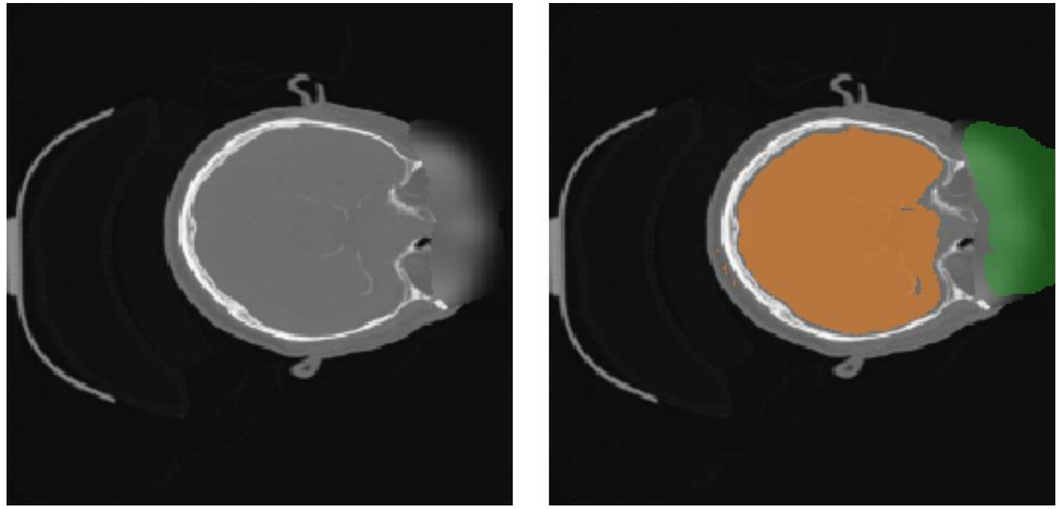

84.Png du test set

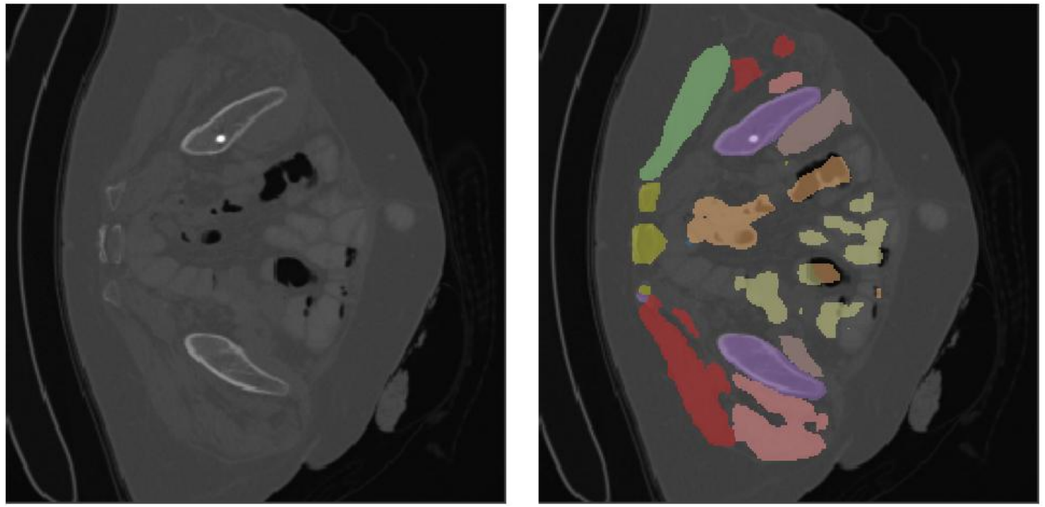

113.Png du test set

Un masque de segmentation non robuste

→ Recherche de structures uniformément segmentés
→ Plus de classes nécessaires prédites

CHANGER D'IMAGE POUR AVOIR LA LEGENDE UNIFORME ET SUR UN NOUVEAU MODELE DE REFERENCE QUE JE VAIS ETABLIR PUIS LE FAIRE APRES COMPARAISON ET CA SERA INTERESSANT

NE DEVRAIT PAS ETRE LA A CE MOMENT CAR CE SONT DES IMAGES DU TEST SET

Identification des contraintes --> CHANGER LE TITRE

Des marges d'amélioration perceptibles

Quelques take aways :

- **Mettre le plot de la validation sur le set d'entrainement avec le crop (peut être en jaune)**
- **Me demander ce que j'en retiens**

PRIOR KNOWLEDGE

Identification des contraintes

Un matériel d'entrainement inexploité : Labels et classes d'images liés ?

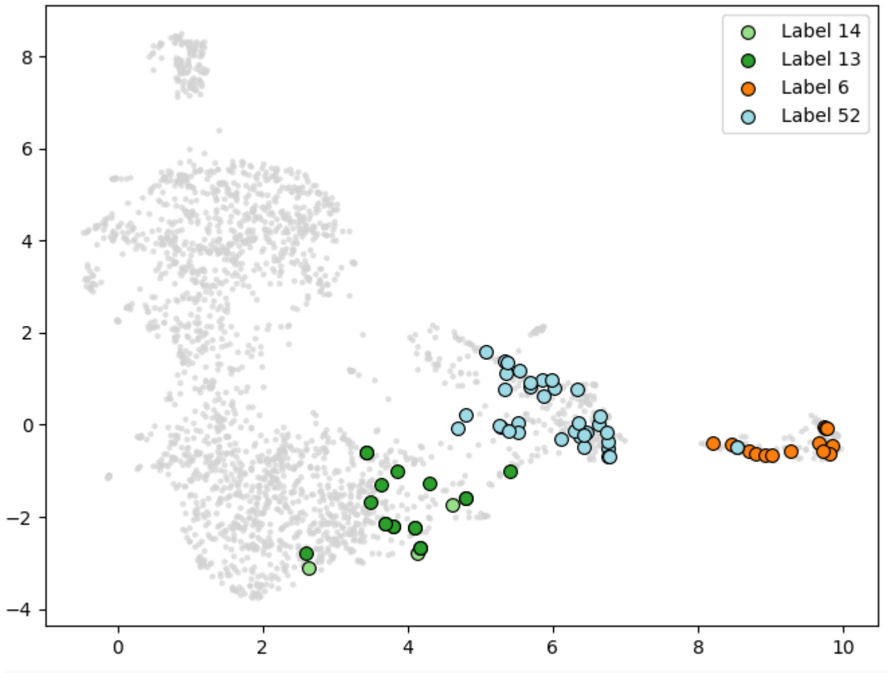

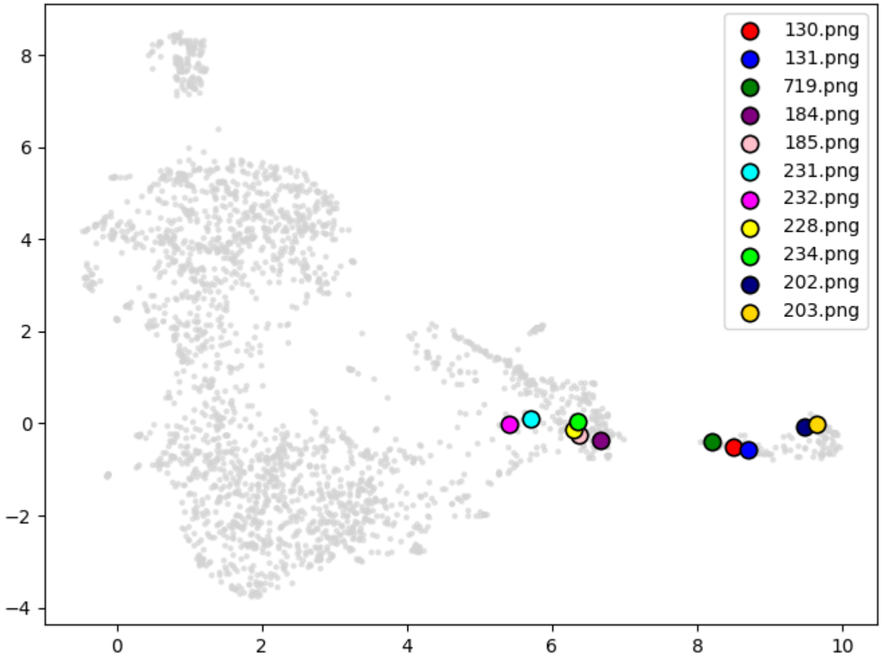

Le label 52 est une vertèbre cervicale au niveau du cou, le label 12 est le visage et le label 6 associé est la tête

Focus premier sur les têtes contient les labels 6 et 12 –> les plus proéminents en aire couverte moyenne par image

Séléction de scanners couvrant la tête

Préciser que j'ai pas mis 12 car souvent c'est la même chose que 6

Identification des contraintes

Un matériel d'entrainement inexploité

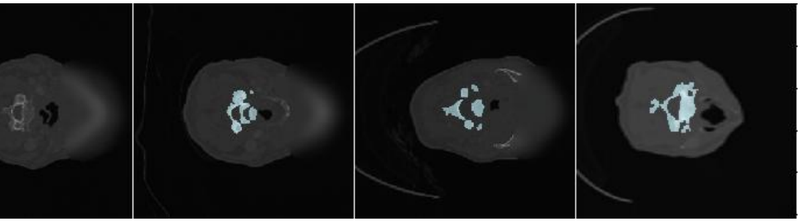

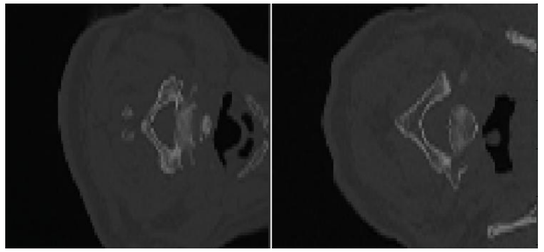

coupe axiale de scanner (CT) du cou
Label vertèbre cervicale

DIRE A L'ORAL

→ Les CT Scan présentent des caractéristiques différentes selon l'axe de la coupe transverse et le dataset annoté couvre difficilement l'entièreté du corps humain

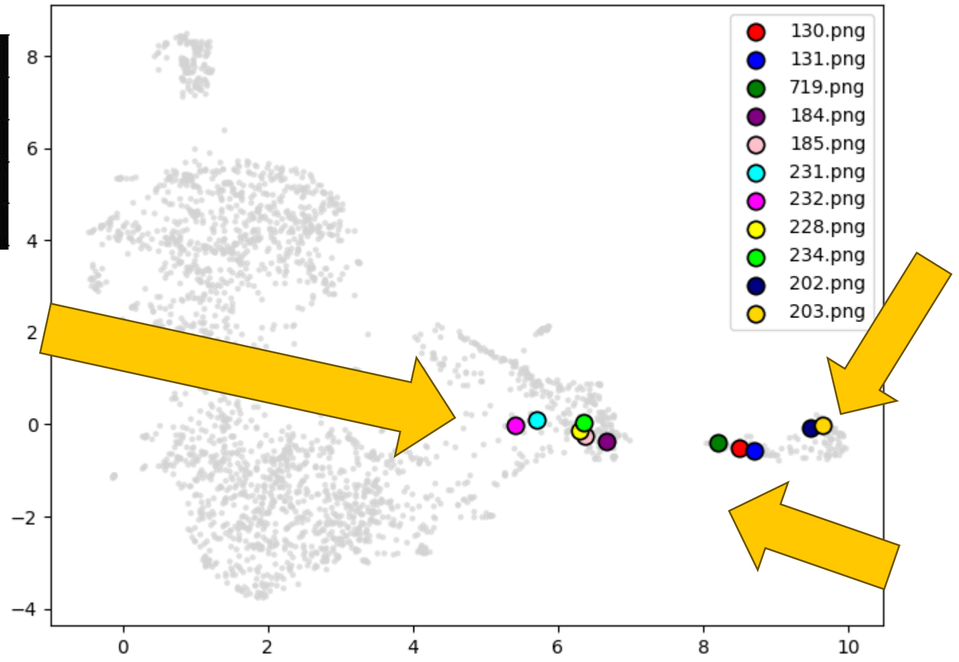

Insérer l'information de la partie du corps scanné dans l'inférence des labels

→ Idée est de forcer le modèle à piocher des labels communs pour des scanners de parties communes à des axes différents

→ Intérêt d'exploiter les images non annotées (+60%) pour améliorer la

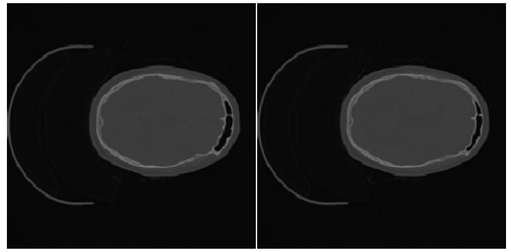

scanner cérébral (cerveau),

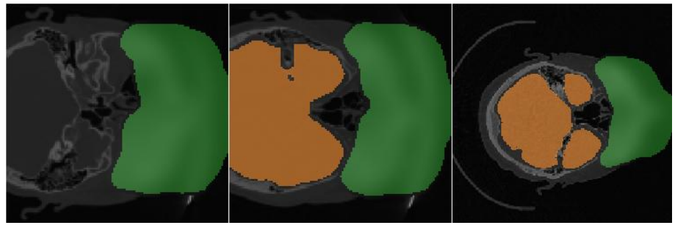

Coupe axiale de la tête, plus précisément niveau du **massif facial**

Labellisation partielle sur des images communes à vues différentes

- Groupe d'images proches à des labels communs restreints

Identification des contraintes

Un matériel d'entrainement inexploité : Pourquoi le crop ? Inférence à 0,95

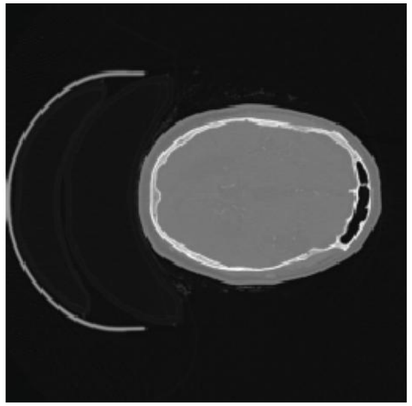

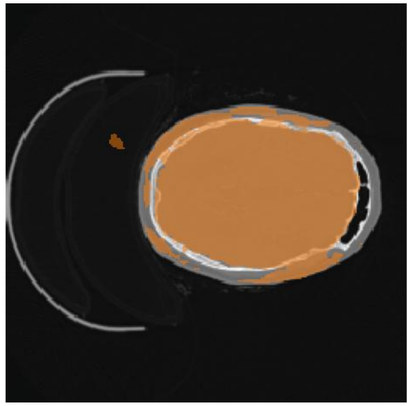

Et ca fait la transition avec le précédent sur le fait que selon le crop, on a une inférence non robuste

```
Classe 0 : 0.9966
Classe 20 : 0.7336
Classe 52 : 0.9581
```

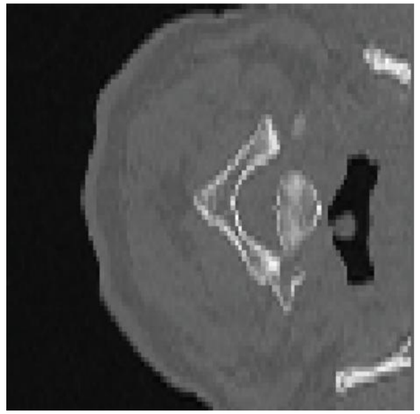

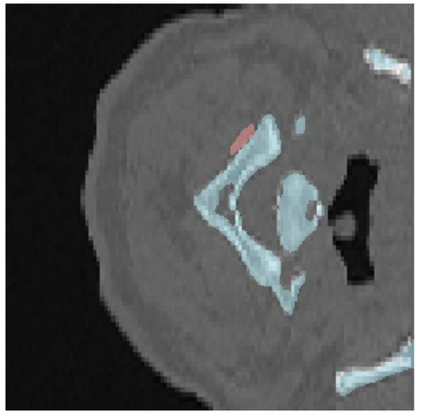

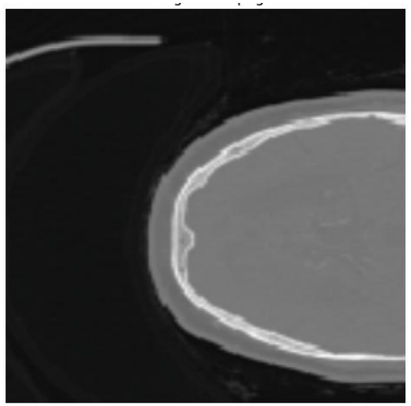

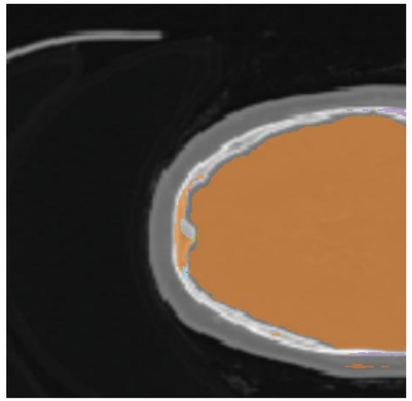

```
Confidence moyenne par classe prédite :
Classe 0 : 0.9911
Classe 2 : 0.2941
Classe 6 : 0.9935
Classe 8 : 0.5911
Classe 14 : 0.2584
Classe 23 : 0.3425
Classe 24 : 0.6755
Classe 42 : 0.5738
Classe 44 : 0.2766
Classe 54 : 0.3996
```

```
Classe 0 : 0.9954
Classe 7 : 0.4634
Classe 8 : 0.6346
Classe 20 : 0.6782
Classe 52 : 0.9701
```

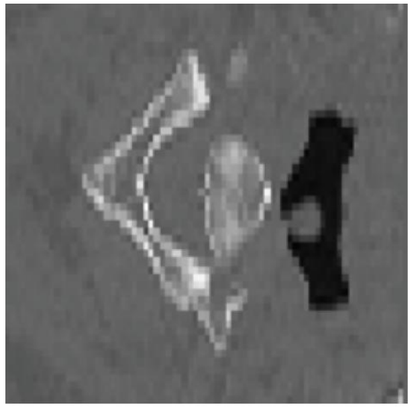

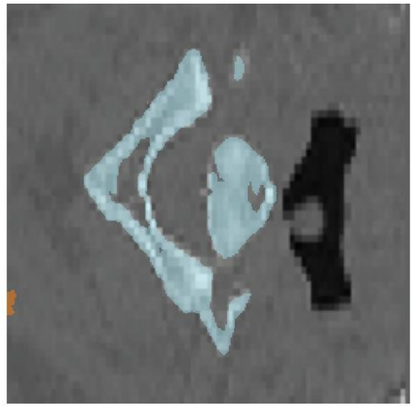

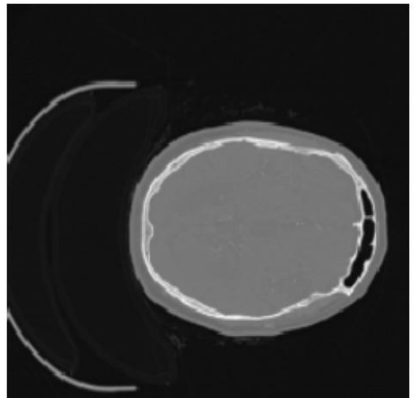

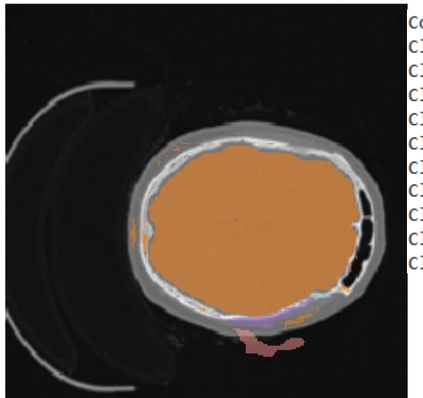

```
Confidence moyenne par classe prédite :
Classe 0 : 0.9902
Classe 2 : 0.2323
Classe 6 : 0.9864
Classe 8 : 0.5442
Classe 20 : 0.4281
Classe 21 : 0.6664
Classe 23 : 0.4533
Classe 24 : 0.8416
Classe 42 : 0.6431
Classe 54 : 0.5087
```

```
Classe 0 : 0.9885
Classe 6 : 0.5519
Classe 20 : 0.5153
Classe 52 : 0.9724
```

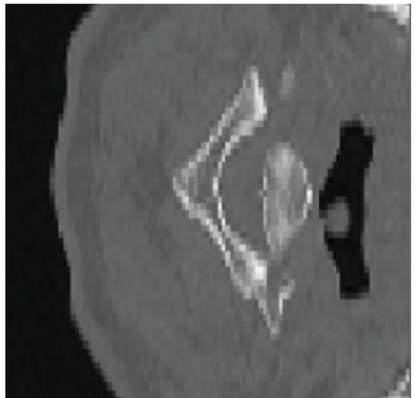

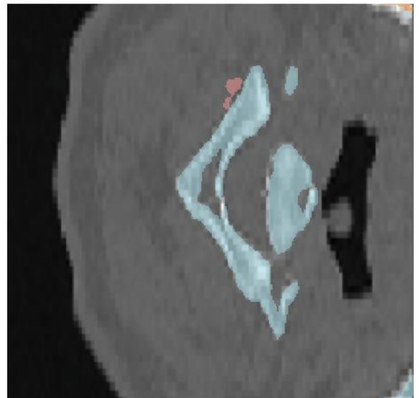

Identification des contraintes

Un matériel d'entrainement inexploité : Pourquoi le crop ? Inférence à 0,95

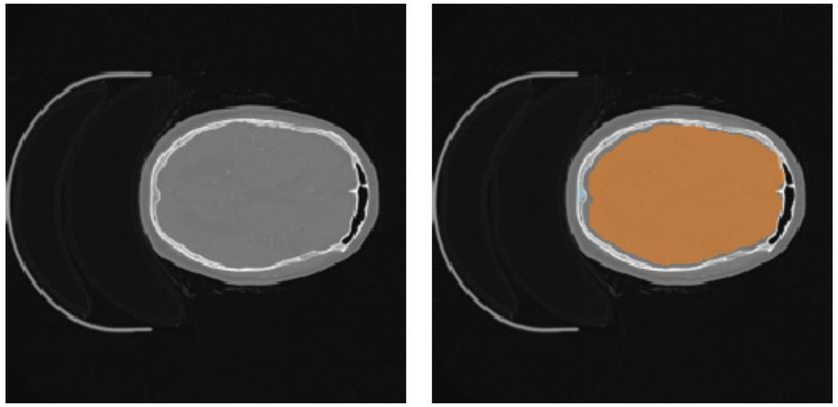

Et ca fait la transition avec le précédent sur le fait que selon le crop, on a une inférence non robuste
Et trouver un moyen de zoomer sur les imperfections

```
Classe 0 : 0.9966
Classe 20 : 0.7336
Classe 52 : 0.9581
```

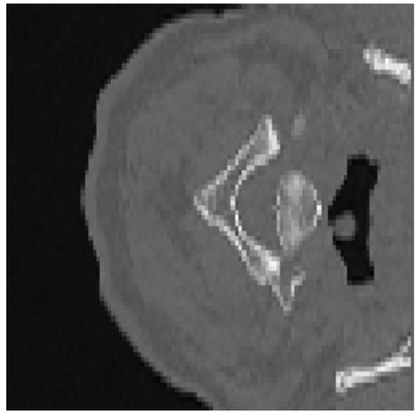

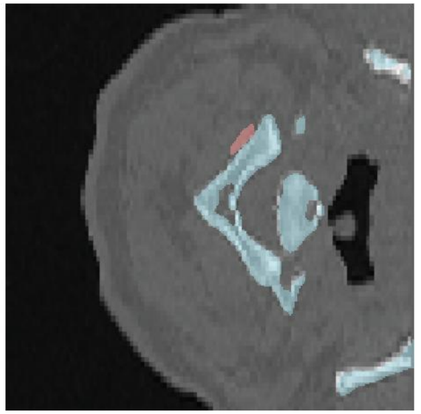

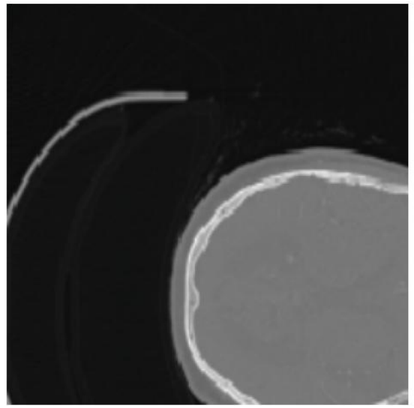

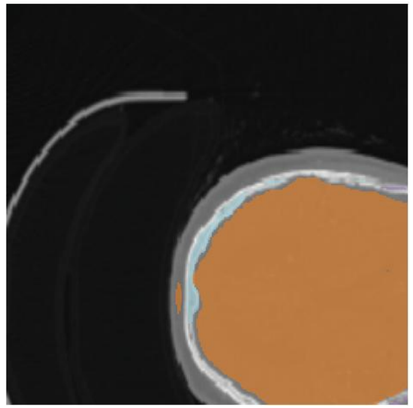

```
Classe 0 : 0.9923
Classe 6 : 0.9931
Classe 23 : 0.4840
Classe 24 : 0.6220
Classe 52 : 0.8605
```

```
Classe 0 : 0.9833
Classe 6 : 0.8717
Classe 39 : 0.4844
Classe 47 : 0.6046
Classe 52 : 0.9783
```

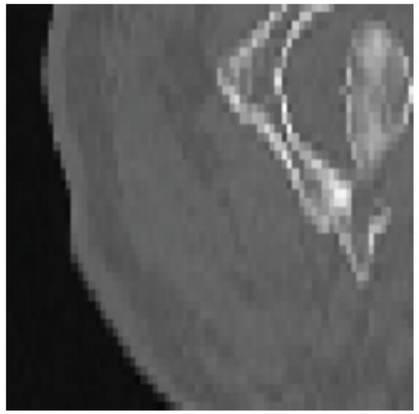

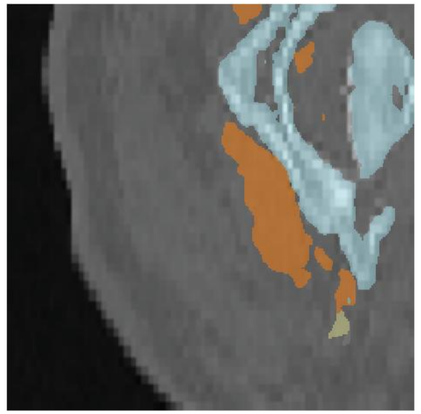

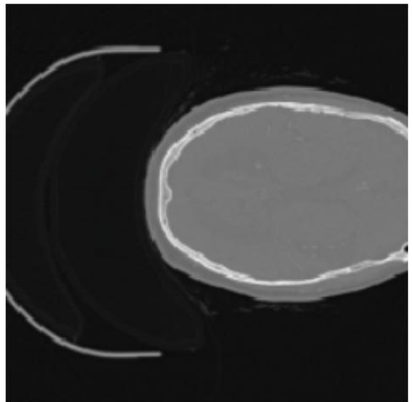

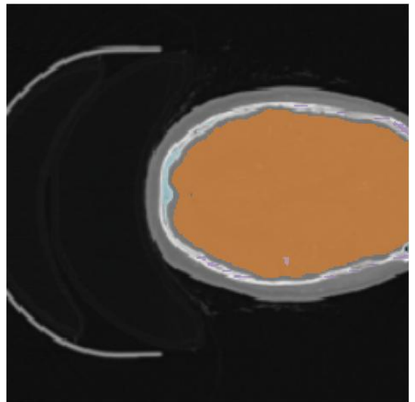

```
Classe 0 : 0.9952
Classe 6 : 0.9696
Classe 23 : 0.6709
Classe 24 : 0.7270
Classe 36 : 0.5714
Classe 52 : 0.7637
```

```
Classe 0 : 0.9832
Classe 6 : 0.8488
Classe 47 : 0.3787
Classe 52 : 0.9754
```

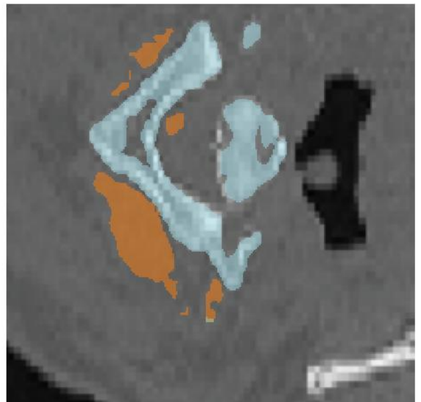

UNIMATCH : faire la transition et de dire qu’on va faire le semi – supervised learning

Une méthode semi-supervisé : Pseudo-labelling

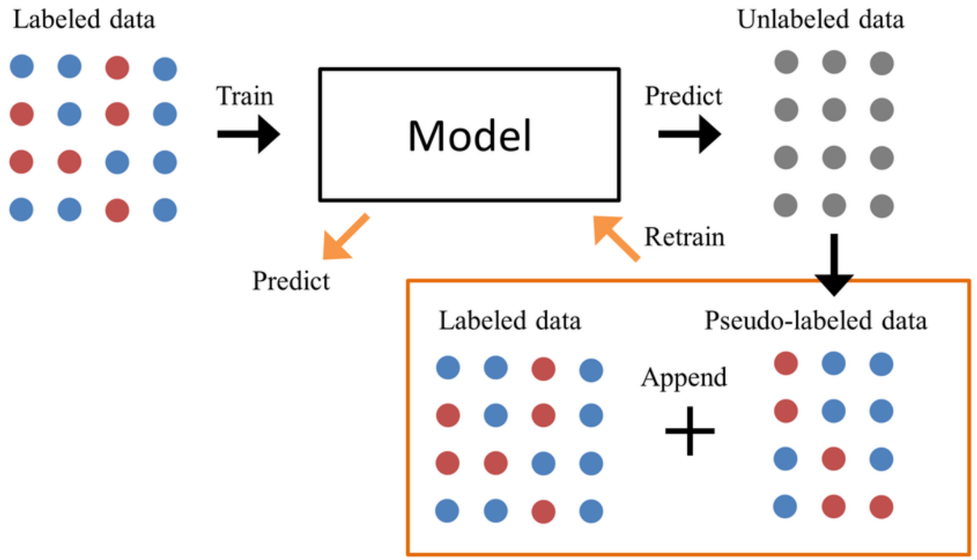

Dire l'inconvénient par rapport au modèle de base

Principe du pseudo- label :

→ entrainer un modèle initial sur le dataset labellisé Dl

→ Générer des prédictions sur le dataset non-labellisé Du

→ **Assigne en tant que label ces prédictions selon un seuil de confiance choisi**. Le score de confiance correspond au softmax des activations

→ Ainsi, plus la probabilité associée à une prédiction est élevée, plus elle indique un "niveau de confiance élevée. Ainsi, nous choisissons de fixer un **seuil pour l'assignement des pseudo-labels et les images assignés forment Du**

→ **combiner le dataset labellisé Dl avec le dataset pseudo-labellisé Du pour former un dataset D = (Dl ∪ Du) et ré-entrainer**

Une méthode semi-supervisé : *consistency regularization*

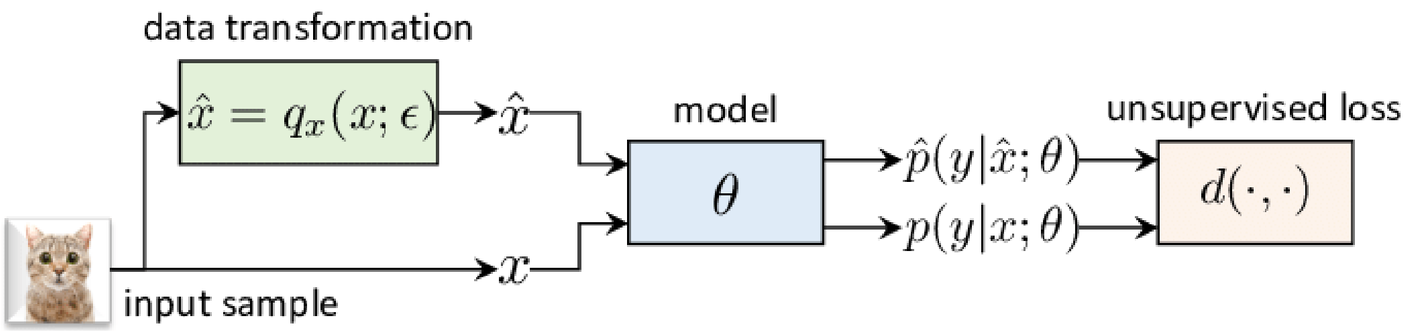

Principe de la *consistency regularization*:

→ l'objectif principal est d'utiliser les modèles de Deep Learning à gagner en régularisation et en robustesse.

→ perturber les données pour s'assurer qu'elles produisent des résultats similaires i.e. que les images perturbées doivent être probabilistiquement proches de produire le même masque de segmentation. (**Demander à chat Gpt ce que ca veut dire)**

Essayer de faire du bleu et jaune avec Nanobanana ou paperbanana

Et dire que c'est un enjeu étant donné la situation (slide 30)

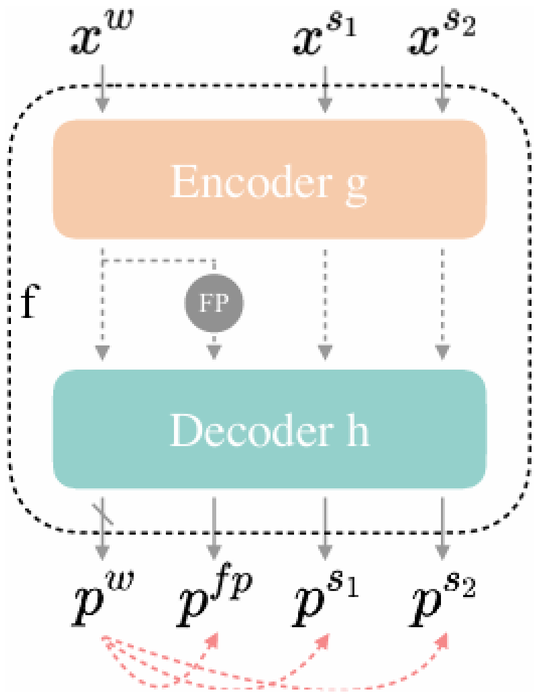

$$\mathcal{L}_u = \frac{1}{B_u} \sum \mathbf{1}(\max(p^w) \geq \tau) \Big(\lambda H(p^w, p^{fp}) + \frac{\mu}{2} \big(H(p^w, p^{s_1}) + H(p^w, p^{s_2}) \big) \Big)$$

Lihe Yang et al., *Revisiting Weak-to-Strong Consistency in Semi-Supervised Semantic Segmentation*. 2023.

→ Crée une perturbation « faible » x^w et des perturbations « fortes » x^{s_1}, x^{s_2} au niveau de l'image non labellisée x^u.

→ **Pseudo-labellise l'image x^w selon un confidence threshold τ de 0,95 d to filter noisy labels**

→ **Le masque résultant p^w sert de ground-truth de supervision aux prédictions générées du modèle provenant des fortes perturbations aux niveau de l'image p^{s_1}, p^{s_2} et la prédiction perturbée au niveau des features p^{fp} → changer peut-être le le p^w en y^w**

→ **regularizes prediction of the sample under strong perturbations to be the same as that under weak perturbations. H minimizes the entropy between two probability distribution**

$$H := Cross\ Entropy$$

with y ground-truth mask and $\hat{y}$ predicted logits for a labeled image x^s

$$\mathcal{L}_s = \frac{1}{B_s} \sum Dice(y, \hat{y})$$

$$\mathcal{L}_u = \frac{1}{B_u} \sum \mathbf{1}(\max(p^w) \geq \tau) \Big(\lambda H(p^w, p^{fp}) + \frac{\mu}{2} \big(H(p^w, p^{s_1}) + H(p^w, p^{s_2}) \big) \Big)$$

$$\mathcal{L} = \frac{1}{2}(\mathcal{L}_s + \mathcal{L}_u)$$

→ Mixed batch

→ Changer peut-être L_s

→ **Weighting parameters :** λ, μ

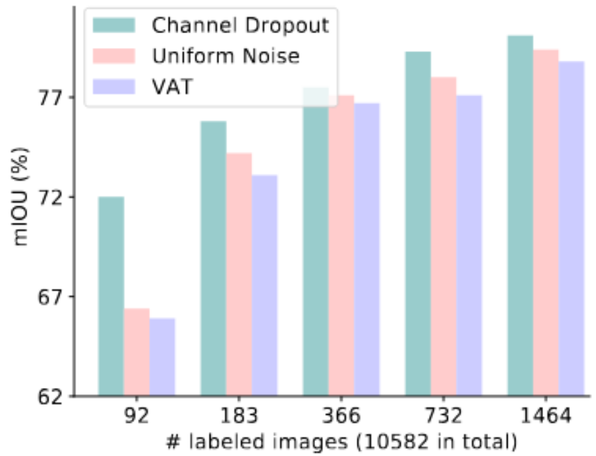

Choix des perturbations :

→ **Crop as weak perturbation**: : change légèrement la fenêtre d'observation sans altérer radicalement la forme des structures et permet de capturer des caractéristiques locales. **On justifiera le crop par l'exemple de l'image 462.png**

→ **CutOut as strong perturbation**: crée des occlusions et des combinaisons complexes d'objets, encourageant la robustesse du modèle. *Geoff French et al., Semi-supervised semantic segmentation needs strong, high-dimensional perturbations.*

→ **Channel Dropout as our feature perturbation :** dropout of 50% probability, which is inserted at the intersection of the encoder and decoder

Paramètre	Valeur
Optimiseur	Adam
Learning rate (phase warm-up)	1×10^{-3}
Learning rate (phase UniMatch / fine-tuning)	5×10^{-4}
Dropout (feature perturbation)	0.4
Strong perturbation	CutMix
Seuil de confiance τ	0.6
λ	0.5
μ	0.5

Séléction des hyperparamètres :

→ Dropout à 0.5

→ Seuil de confiance : 0.95

→ Les autres hyperparamètres sont choisis empiriquement

Modifier ce tableau pour les réels paramètres et préciser le Kfold et
Et préciser que c'est un batch mixte

Kfold : 5 folds

Expliquer le post-processing avec le UMAP et une image de la tête

Expliquer en quoi c’est important

Modifier ce tableau pour les réels paramètres et préciser le Kfold et
Et préciser que c’est un batch mixte

Kfold : 5 folds

Objectif du projet

Vue finale

Rajouter des éléments sur ma méthode :
Kfold, post-proc(field knowledge) et autres

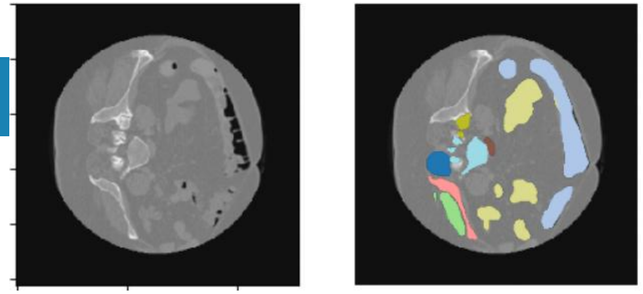

Données d'entrainement partiellement annotés

Images

- Images 256x256 pixels
- Images **partiellement annotées de coupe transverse**
- **Masque de segmentation (classe par pixel)**

Modèle de segmentation pré-entrainé

- Fiabilité de quelques labels
- **Des données d'entrainement pas exploités**

Phase d'ajustement (fine-tuning)

- Entrainement du modèle via Deep Learning sur nos données d'entrainement
- Choix **d'une méthode semi-supervisé exploitant le pseudo-labeling(fiabilité par seuil) et consistency regularization**

UNIMATCH

Evaluation

- Evaluation quantitative et quantitative selon la DICE
- Sélection d'hyperparamètres

Modèle de segmentation robuste et précis

4. Résultats

Résultats sur le set de validation

Avec ma méthode : montrer le résultat sur le set de validation (compute_dice_plot avec post-processing)

Classement

Rang	Date	Participant(s)	Score public
1	1 septembre 2025 22:24	lleyrat	0,5772
2	18 mars 2025 17:36	egardes	0,5519
3	17 mars 2025 08:11	tomrvd & v-l	0,5496
4	**1 juillet 2025 14:46**	**Robenson**	**0,4718**
5	16 mars 2025 23:46	Abderrahmane & noambsf	0,4248
6	13 mars 2025 22:48	leobutanets & arthur_bresnu	0,3985
7	14 mars 2025 22:29	Nezio	0,3805
8	13 mars 2025 09:49	Guillaume-HJ & emiliepic	0,3779
9	2 juin 2025 10:29	nnavarro & carloscuevas	0,3681
10	15 mars 2025 23:28	wludington & hlevechin	0,3581

Résultats

Une plus-value apportée par l'apprentissage semi-supervisé

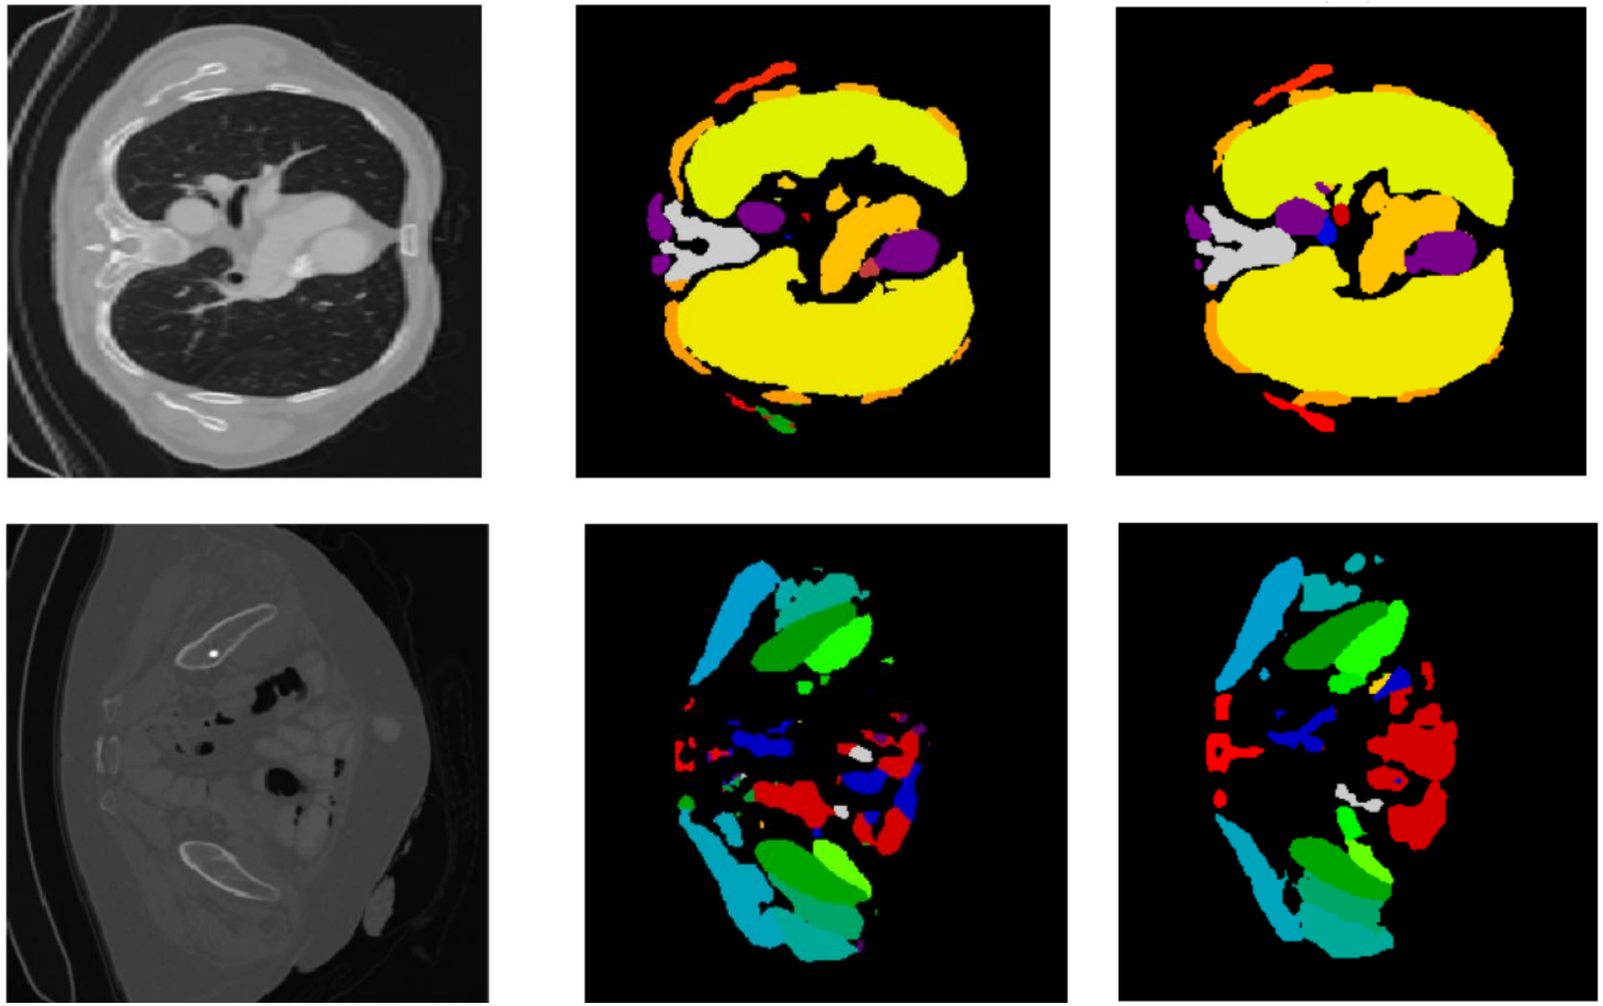

Modèle entrainé avant et après UniMatch

Reprendre la trame des slides 23,28 et 29 avec ces deux images : montrer l'amélioration : Base, Kfold base, Unimatch puis postpro

CHANGER LES IMAGES POUR AVOIR LES BONNES L2GENDES, PAS DE FOND NOIR ET LE BON MODELE AVEC PROCESSING

Un masque de segmentation plus robuste qualitativement

Résultats

Une plus-value apportée par l'apprentissage semi-supervisé

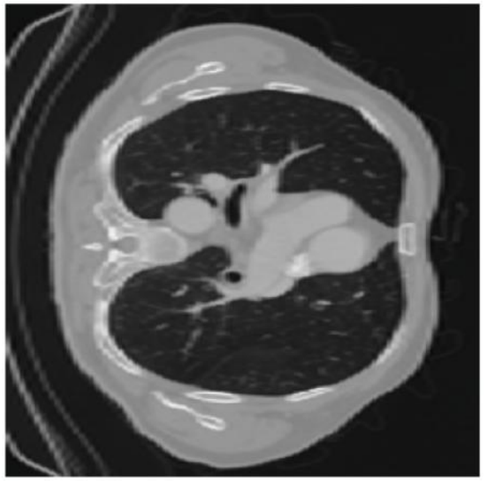

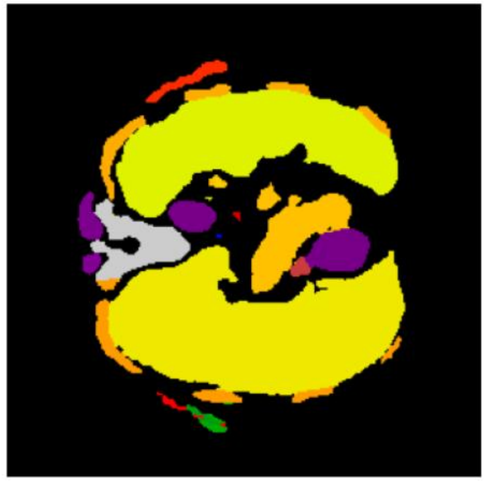

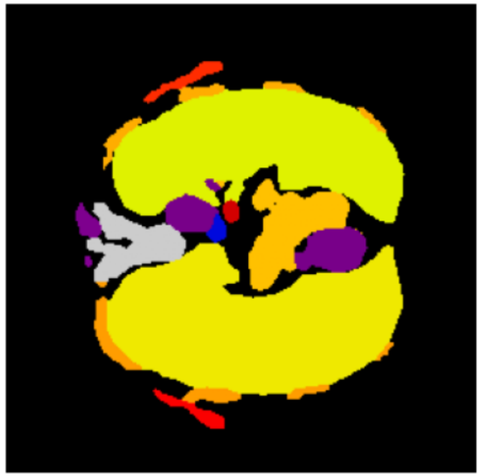

Modèle entrainé avant et après UniMatch

Reprendre la trame des slides 23,28 et 29 avec l'image 84.png du test set
: montrer l'amélioration : Base, Kfold base, Unimatch puis postpro

CHANGER LES IMAGES POUR AVOIR LES BONNES L2GENDES, PEUT ETRE FOND NOIR ET LE BON MODELE AVEC PROCESSING

Un masque de segmentation plus robuste qualitativement

Résultats

…. et le field knowledge

Sur la tête : Améliorations visuelles

Sur les cuisses

Notifier aussi les histoires de score de confiance avec et sans :

Gradation : 5 folds – 5 folds combined phase – 5 folds combined phase + postprocessing

MONTRER SUR IMAGES D'INTERET LE RESULTAT

Ablation study sur le UniMatch (one-single view & double view) sur mon split habituel : qualitatif et quantitative (score) sur le test set et/ou le val set

Beaucoup plus accentué sur les images que j'avais pris en otage (la tête et les cuisses)

- **0,4578 (loss) pour la phase 1**
- **0,4825 (loss) pour la phase 2 (20 epochs à 10e-4) et avec juste une view**
- **? (loss) pour la phase 2 (20 epochs à 10e-4) et avec doubl view**
- **0,4742 (loss) pour la phase 1 + 20 epochs à 10e-4 et batch=**
- **? Pour une phase de pseudo-labeling avec les mêmes paramètres (EXPLIQUER LE PROBLEME)**

Pour assurer que c'est pas uniquement une histoire d'entrainement : préciser qu'on a pas fait plus par souci computationel

Ablation study

Ablation study sur un niveau de Dropout plus faible, le niveau de confiance (threshold), sans le feature perturbation

Ablation study sur des batch sizes différents à la phase 1 et à la phase 2

Report le résultat de mon test sur mon second compte

Pas de gain pour un niveau plus faible et sans le feature perturbation se fier au papier

Pour assurer que c'est pas uniquement une histoire d'entrainement : préciser qu'on a pas fait plus par souci computationel

Effet de score sur mon post-processing sur le test-set (**Les résultats seront sûrement à changer)**

- **0,6251**
- **0,6267**

Résultats sur le set de validation

Avec ma méthode : montrer le résultat sur le set de validation (compute_dice_plot avec post-processing) ou juste sur mon split habituel lorsque je connaitrais ma technique finale

5. Discussion et conclusion

Conclusion

Thank you.

Choix de la fonction de perte non supervisée :

Fonction de perte en seconde phase Le modèle est réentrainé en considérant de base les poids appris pendant la première phase d'entrainement sur le dataset $D = (D_l \cup D_u)$ avec D_u le dataset contenant les pseudo-masks Soit x une image d'entrée, $\hat{y}_w$ les masques produits par la perturbation faible, $\hat{y}_{fp}$ les masques issus de la version perturbée au niveau des features , y_{s1}, y_{s2} les sorties des deux perturbations fortes, y les labels ground-truth (valeurs dans $\{0, \ldots, 54\}$) et $\bar{y}$ le pseudo-label.

$$\mathcal{L} = \mathcal{L}_{sup} + \lambda \mathcal{L}_{fp} + \mu \mathcal{L}_{img}.$$

- $\mathcal{L}_{sup}$: perte supervisée sur les images labelisées ou pseudo-labellisées :

$$\mathcal{L}_{sup} = \mathrm{Dice}(\hat{y}_w, y).$$

- $\mathcal{L}_{fp}$: perte de consistance entre la prédiction perturbée (*feature-perturbed*) aux pseudo-labels :

$$\mathcal{L}_{fp} = \mathrm{Dice}(\hat{y}_{fp}, \bar{y}).$$

- $\mathcal{L}_{img}$: perte image-niveau moyennée entre les deux *strong-views* et le pseudo-label :

$$\mathcal{L}_{img} = \frac{1}{2}\Big(H(y_{s1}, \bar{y}) + H(y_{s2}, \bar{y})\Big).$$

- ***H*** cross-entropy function
- ***Dice*** la fonction de coût associée au Dice

Discussion

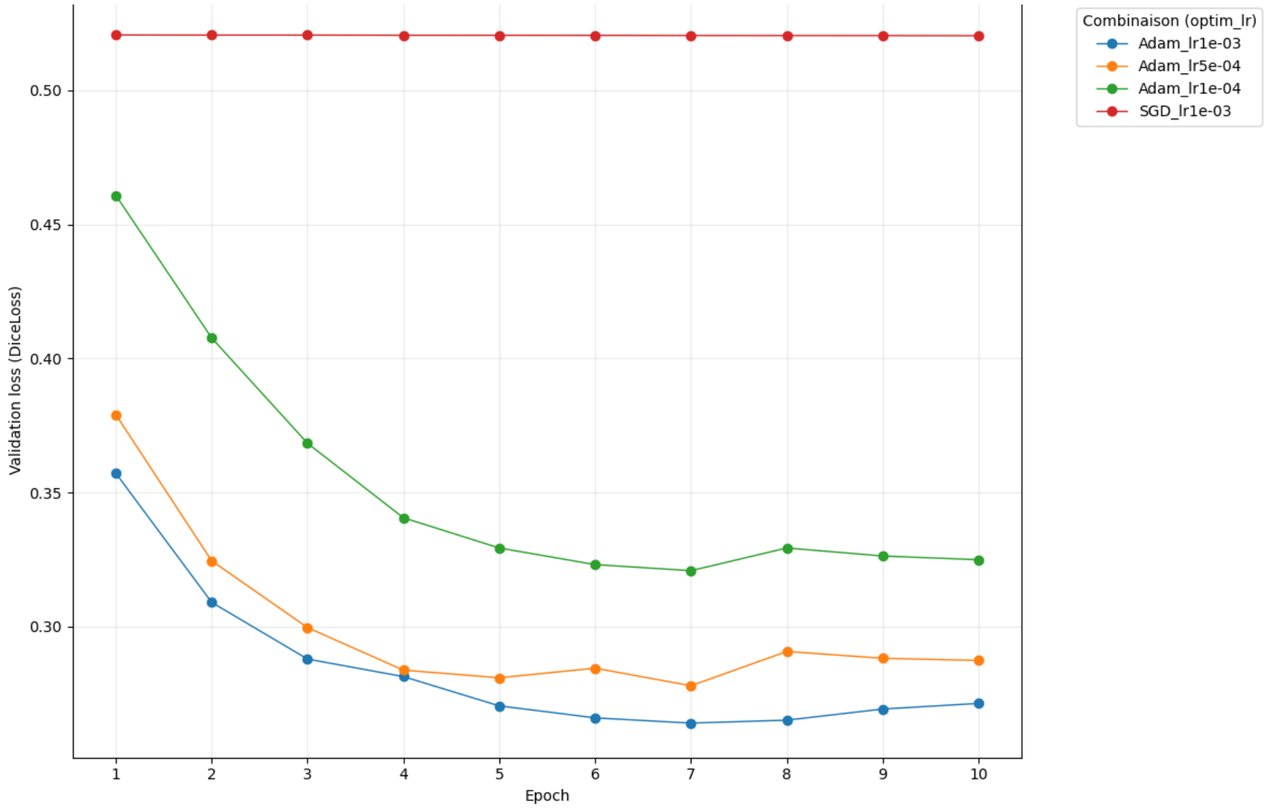

Sélection des hyperparamètres

→ Etude sur les perturbations d'image pertinentes

→ Sélection des poids sur le terme de régularisation

Une plus-value apportée par l'apprentissage semi-supervisé

Phase 1 : 35 epochs et batch à 8 – 0,5740

A examiner les loss sur les 5 folds avec un simple code puis enregistrer le tableau (voir le tableau de la loss ou directement la dice)

Phase 2 (UniMatch et field knowledge) : 30 epochs et batch à 8 (4_4) – 0.6062

KFold summary:

	fold	n_train	n_val	best_phase2_val
0	1	607	152	0.246129
1	2	607	152	0.234711
2	3	607	152	0.270089
3	4	607	152	0.255553
4	5	608	151	0.232552

Résultats

Une plus-value apportée par l'apprentissage semi-supervisé

Méthode	Valeur
SegFormer	0.4232
SegFormer + Pseudo-labeling (seuil à 0.6)	0.4411
SegFormer + UniMatch (seuil à 0.6)	0.4718

→ Utiliser le truc de base

→ Des aires mieux recouvertes

Rang	Date	Participant(s)	Score public
1	1 septembre 2025 22:24	lleyrat	0,5772
2	18 mars 2025 17:36	egardes	0,5519
3	17 mars 2025 08:11	tomrvd & v-l	0,5496
4	**1 juillet 2025 14:46**	**Robenson**	**0,4718**
5	16 mars 2025 23:46	Abderrahmane & noambsf	0,4248
6	13 mars 2025 22:48	leobutanets & arthur_bresnu	0,3985
7	14 mars 2025 22:29	Nezio	0,3805
8	13 mars 2025 09:49	Guillaume-HJ & emiliepic	0,3779
9	2 juin 2025 10:29	nnavarro & carloscuevas	0,3681
10	15 mars 2025 23:28	wludington & hlevechin	0,3581

Identification des contraintes

Un matériel d'entrainement inexploité : Pourquoi le crop ?

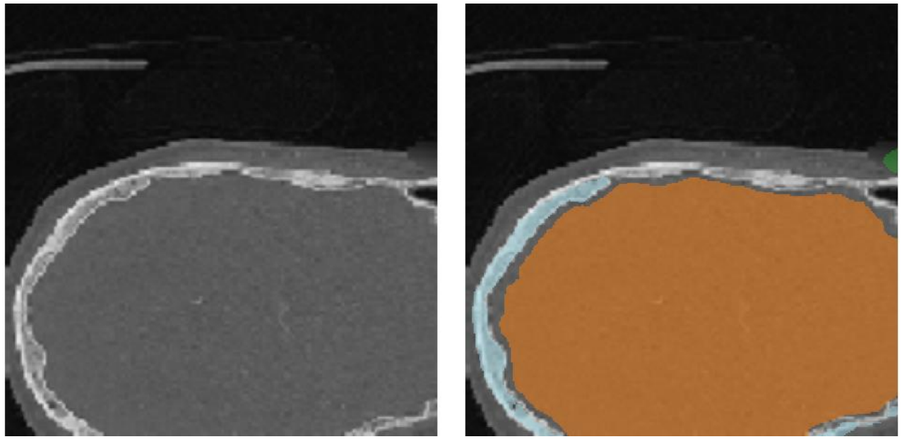

Confidence moyenne par classe prédite :
Classe 0 : 0.9903
Classe 6 : 0.9927
Classe 12 : 0.9013
Classe 52 : 0.8997

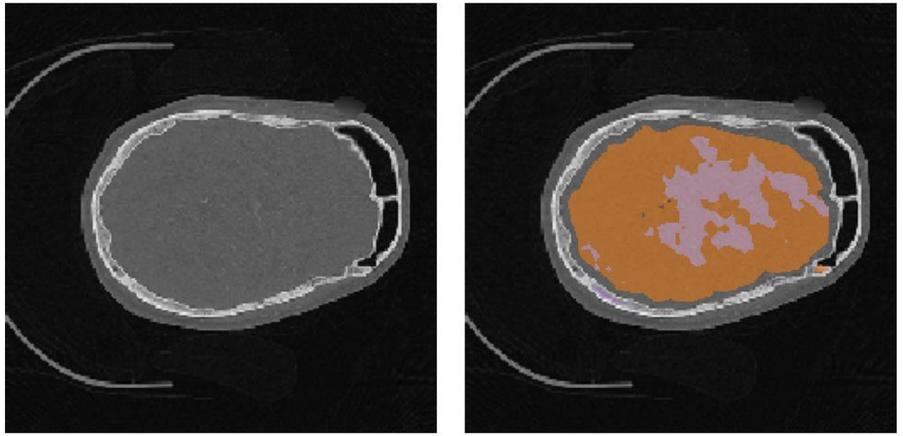

Confidence moyenne par classe prédite :
Classe 0 : 0.9945
Classe 6 : 0.8443
Classe 8 : 0.7293
Classe 23 : 0.4613
Classe 24 : 0.7444
Classe 36 : 0.7518
Classe 43 : 0.7253

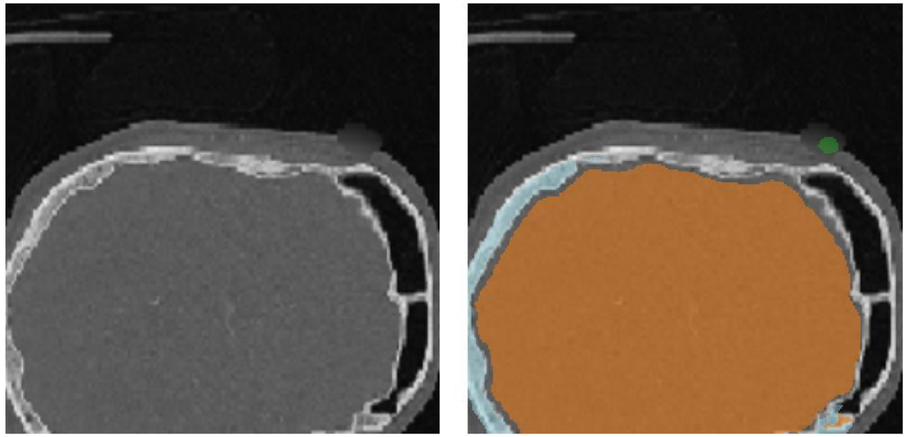

Confidence moyenne par classe prédite :
Classe 0 : 0.9912
Classe 6 : 0.9942
Classe 8 : 0.5393
Classe 12 : 0.7942
Classe 52 : 0.9169

Prédire deux exemples chacune sur le 202,203 en **pseudo_ds** et aussi prédire sur le 231,232 unlabeled pour voir l'absurdité des labels prédits sur le KFOLD sans phase combined et après sur le phase c

Et ca fait la transition avec le précédent sur le fait que selon le crop, on a une inférence robuste

Choix des data augmentations

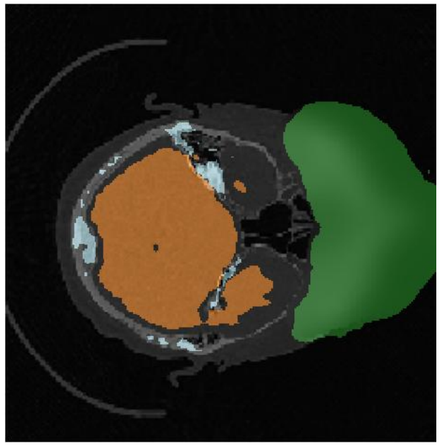

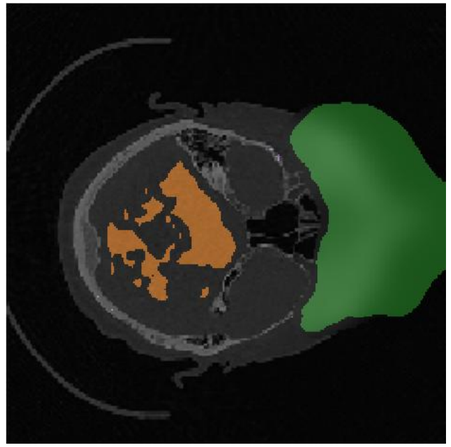

Cutmix + Crop vs Sans cutmix + Crop

- Forcer l'apprentissage de contexte local

Montrer que le grid_masks sans ou avec cutmix

DICE Loss de 0,4341 vs 0.4107 sur l'ensemble de test au bout de 20 epochs

Relabeling

- Identification des images les plus similaires via DINO et tout
- Relabeling (expliquer la méthode et montrer des couples d'images avant après relabeling)
- Phase de checking visuel

Après 10 epochs, on observe une meilleure convergence au bout de 10 epochs

DICE Loss de 0.2634 vs 0.2666 sur l'ensemble de validation
DICE Loss de 0,4276 vs 0.4027 sur l’ensemble de test

Faire en sorte que ça apparaisse après bien comme il faut et préciser qu'on a fixé une SEED pour la reproductibilité

Présentation des données

… et quelques particularités

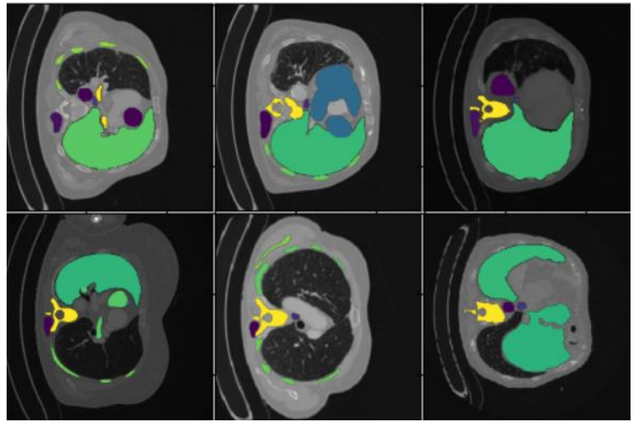

Des images de thorax ; **la colonne vertébrale (en jaune) pas toujours annotée**

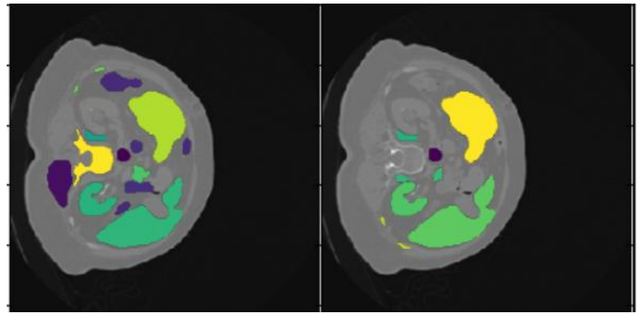

Deux images d'abdomen similaires **mais segmentés différemment**

Données d'entrainement:

→ Des labels n'ont pas la même signification entre les images

→ Des images partiellement annotées et non annotés (759-1241)

Deux principales difficultés :

- **deux structures similaires peuvent être annotées différemment lorsque qu'elles sont annotées.**
- **Les images sont partiellement annotées**

Identification des contraintes

Un matériel d'entrainement inexploité

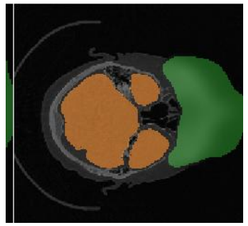

Le plus proche de cette image du set de validation sont

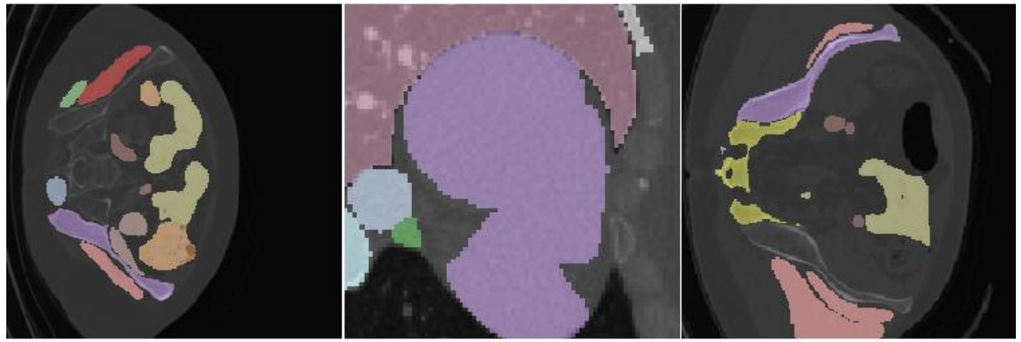

Et dans le reste des unlabeled **949,1235,1598,1196,843**

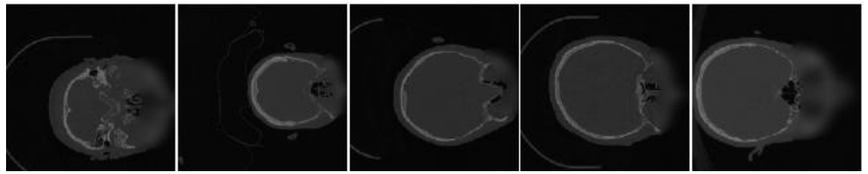

Et dans le test set

- Rien à voir et c'est pas une bonne piste

Conclusion

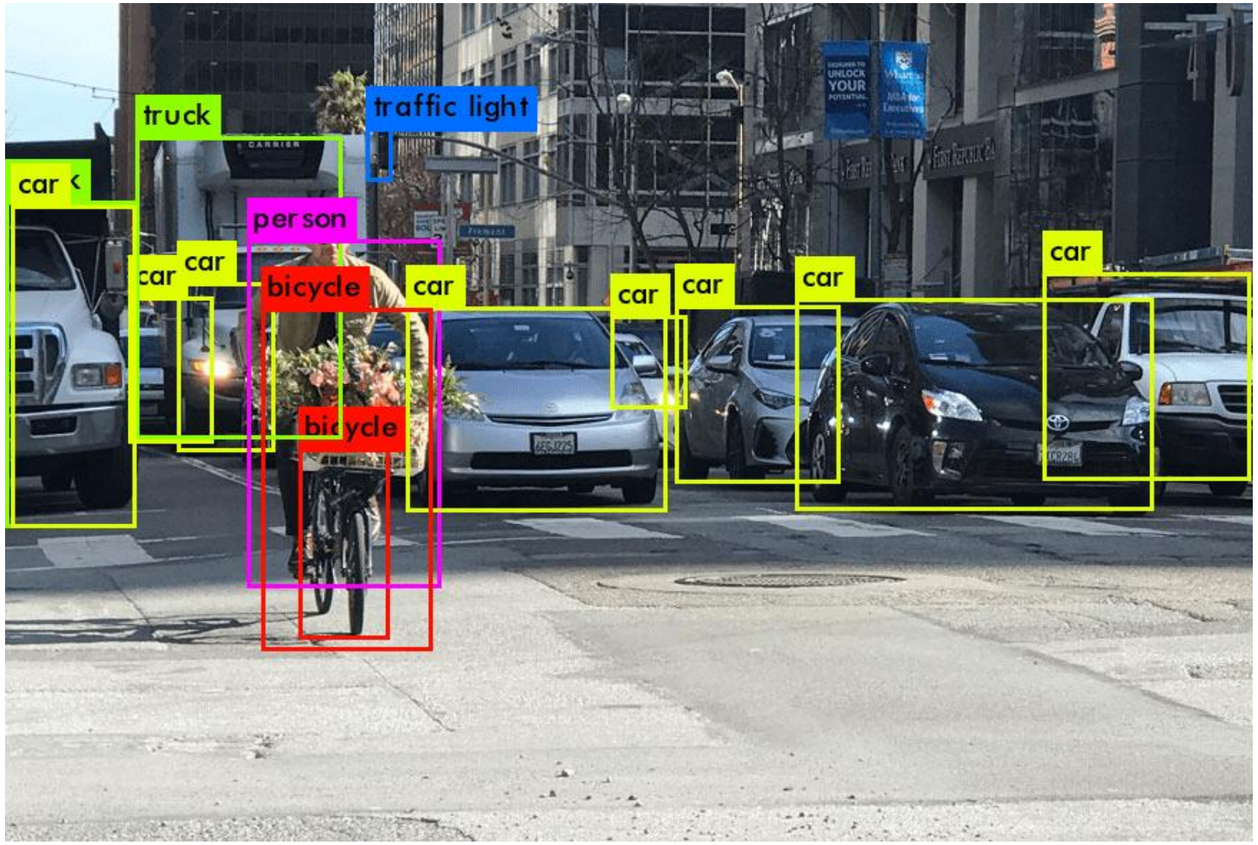

→ Une méthode pouvant être élargie à d'autres tâches de vision par ordinateur (Détection d'objets,..)

→ Alternative à l'annotation humaine coûteuse

→ Dépendante des données annotées (distribution proche du jeu de test)

Identification des contraintes

Un matériel d'entrainement inexploité : Labels et classes d'images liés ?

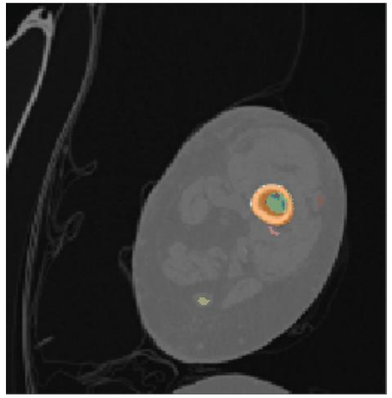

908.png

On sait que c'est les cuisses et que seuls les labels 13 et 14 y sont

```
Confidence moyenne par classe prédite :
Classe 0 : 0.9986
Classe 7 : 0.8885
Classe 13 : 0.2743
Classe 14 : 0.6367
Classe 21 : 0.6118
Classe 25 : 0.3288
Classe 28 : 0.8378
Classe 47 : 0.6206
Classe 51 : 0.4271
```

CHANGER POUR QUE CE SOIT EN ANGLAIS

Cela représente un enjeu car les labels 6,12 font partie des plus présents (cf. Plot)

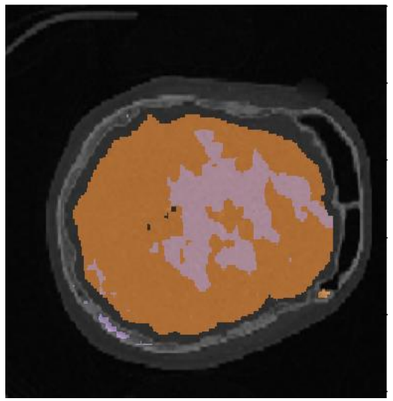

709.png(35 pseudo_ds)

On sait que c'est la tête et que seuls les labels 6,12 et 52 y sont

```
Confidence moyenne par classe prédite :
Classe 0 : 0.9945
Classe 6 : 0.8443
Classe 8 : 0.7293
Classe 23 : 0.4613
Classe 24 : 0.7444
Classe 36 : 0.7518
Classe 43 : 0.7253
```

Voir après mon modèle amélioré ,